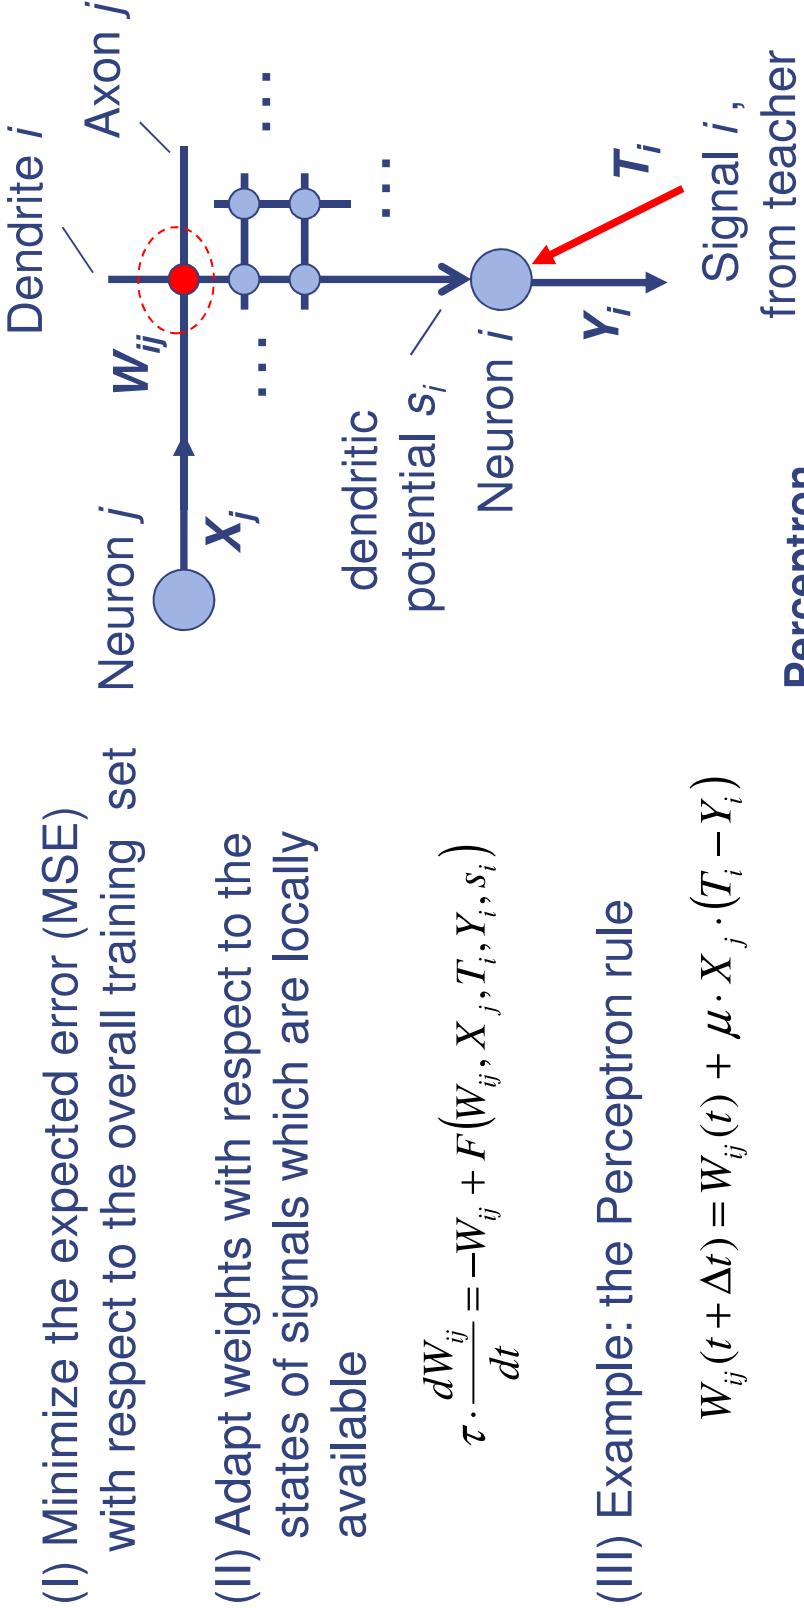


3.5 Pulscodierte Neuronale Netze



3.5.1 Rückblick: Learning and Adaptation, the neural network approach

- Approach

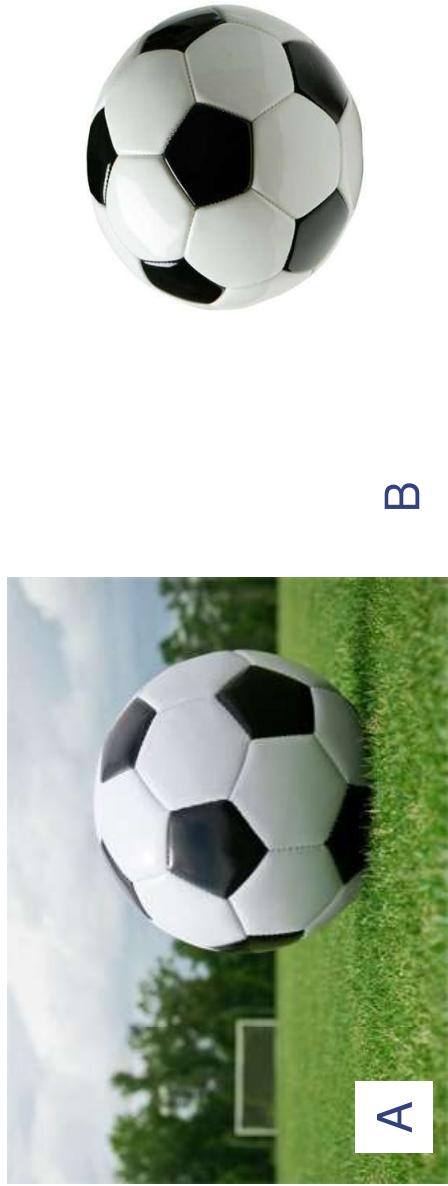


- General restrictions

- (I) Input pattern should contain less than 100 bit
- (II) Input pattern have to origin from identical contexts

3.5.2 Learning from natural Environment: The Binding Problem

- „What is a football“?



- **Problems for large-size applications:**

- (I) Significant neural connections are submerged by insignificant connections
- (II) The required training periods grow to impractical dimensions
- (III) Established artificial neural network models are unable to express *binding*

Aufgabe: Lernen „wie sieht ein Fußball aus“



Kontinuität



unmittelbare
Nachbarschaft



identische
Farbe



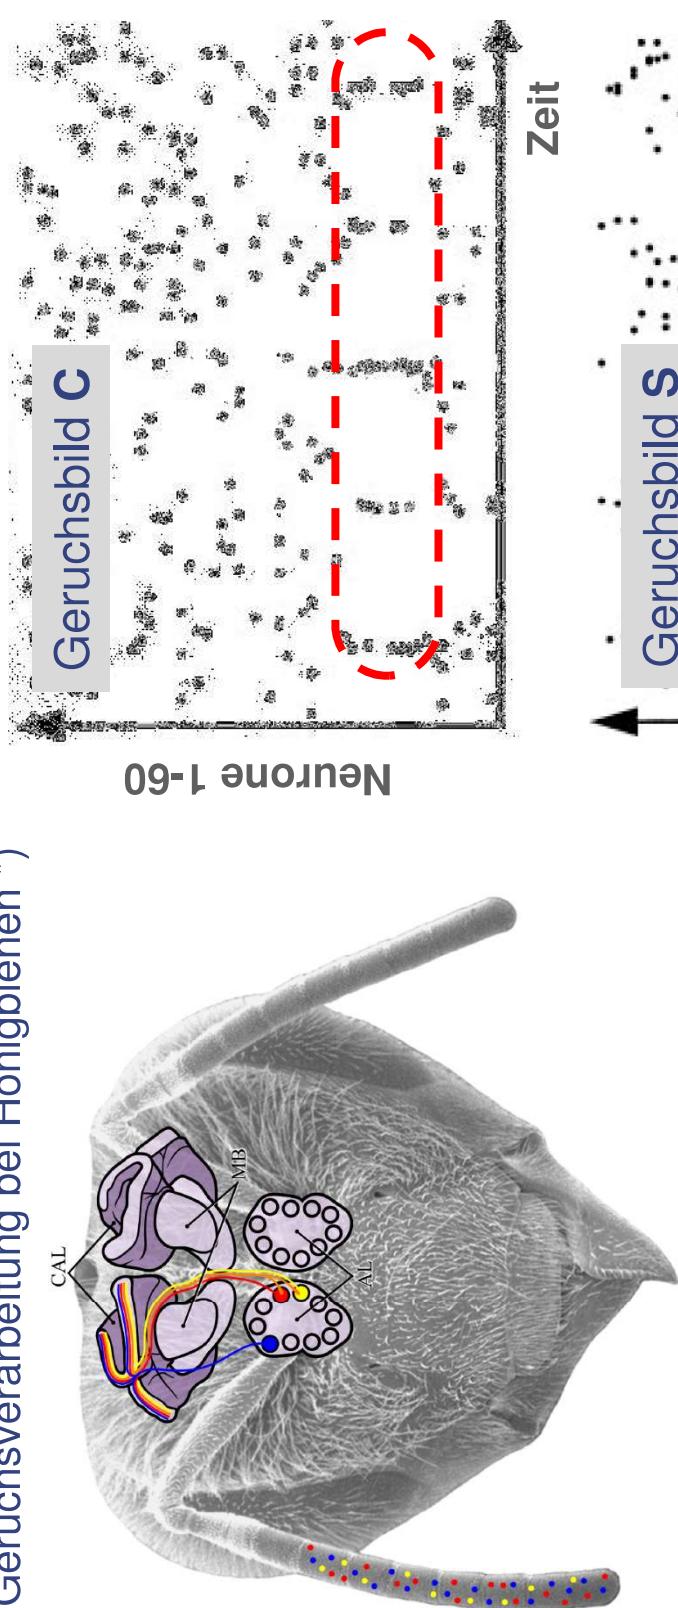
geschlossene
Konturen

1. Objekterkennung erfordert einen **schnellen**, präattentiven Prozess zur Strukturierung der Bildszene
2. **Detection** von Merkmalen
3. **Zusammenbinden** von Merkmalen

Ansatz:

Bindung durch Synchronisation

1. Geruchsverarbeitung bei Honigbienen *)



Geruchsbild C

Neurone 1-60

Geruchsbild S

Neurone 1-60

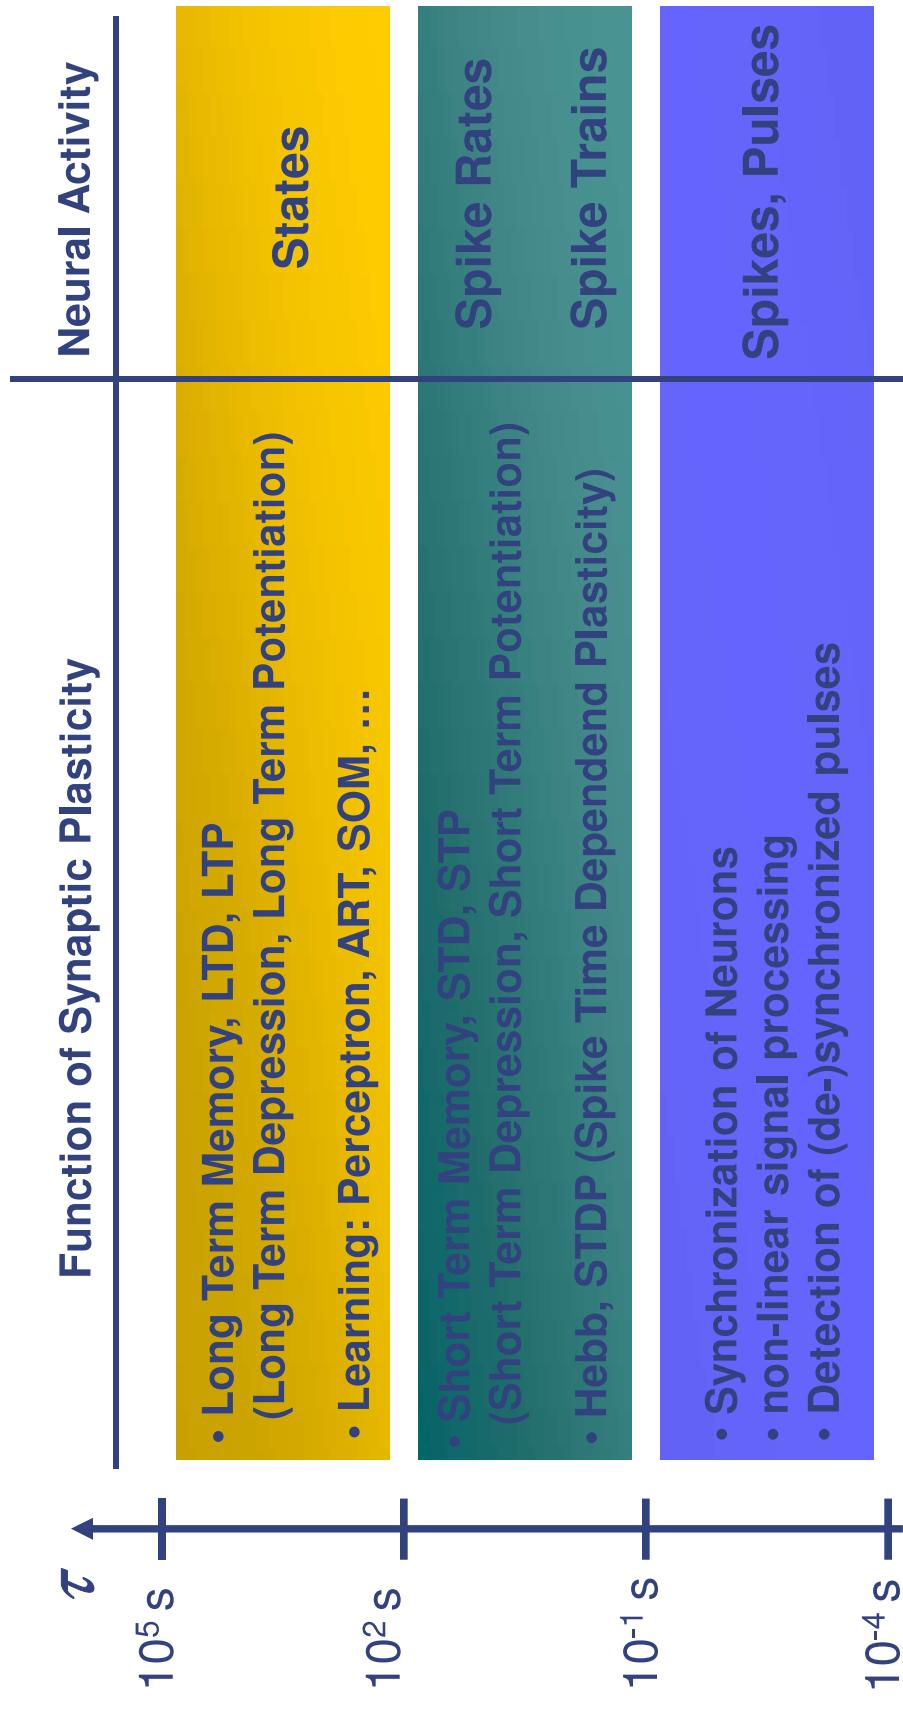
2. Experiment: Honigbienen sollen Geruchsbild C von Geruchsbild S unterscheiden (Training)
3. Bestimmung der neuronalen Aktivität bei Präsentation von **C** und **S**
4. Hinzugabe von **PicROTOXIN** verhindert Synchronisation. Bienen verlieren Fähigkeit, **S** und **C** zu unterscheiden

*) L.Chittka, A.Brockmann: „Perception Space—The Final Frontier“
doi: 10.1371/journal.pone.0034137 PLoS Biol. 3(4): e137. 2005

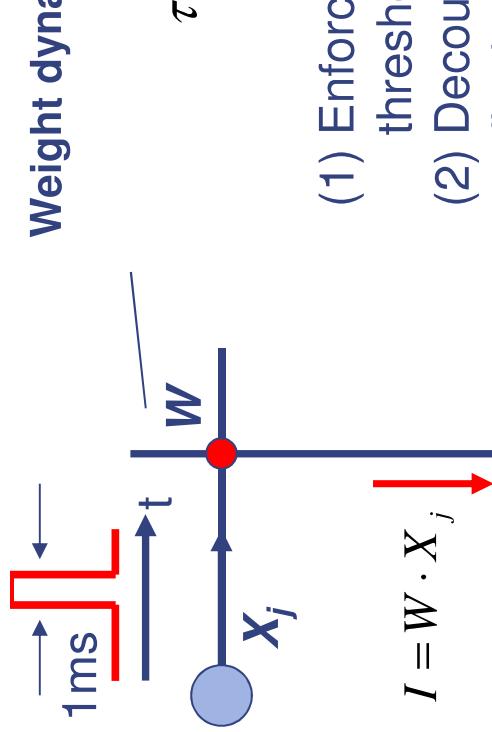
3.5.3 Hypothesis: Fast Binding through Synchronization

- Binding requires a fast dynamic process that **structures data**

- Structuring by means of a **dynamic synapse**: $\tau \cdot \frac{dW_{ij}}{dt} = -W_{ij} + F(W_{ij}, X_j, T_i, Y_i, s_i)$



3.5.4 Dynamic Synapses



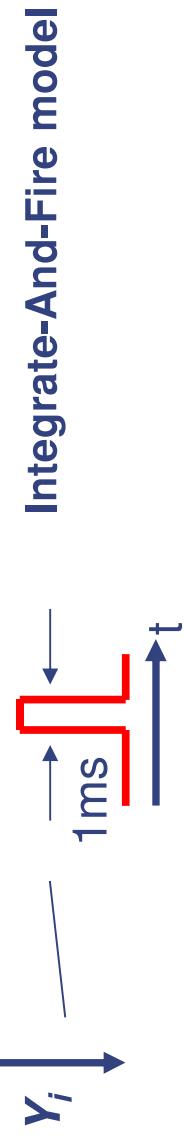
[Heittmann, Ramacher 2002]

$$\tau \cdot \frac{dW}{dt} = -W + \mu \cdot \tau \cdot \left(U - \frac{\theta}{2} \right) \cdot \chi(X_j)$$

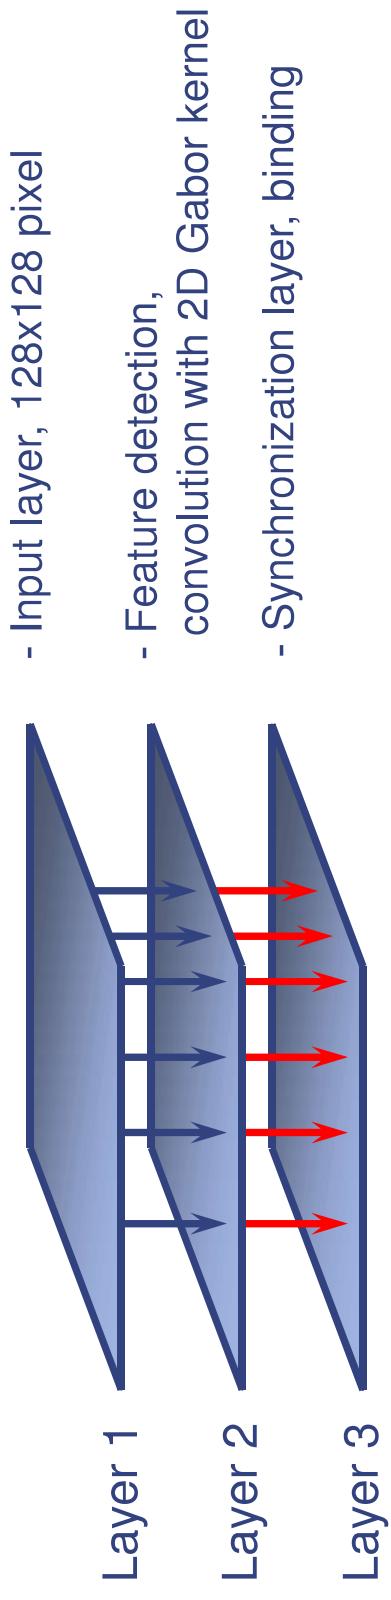
- (1) Enforce coupling if receiving neuron is close to threshold
 - (2) Decoupling if receiving neuron has already fired
- $I = W \cdot X_j$

$$\frac{dU}{dt} = \frac{1}{C} \cdot I = \frac{1}{C} \cdot W(t) \cdot X_i$$

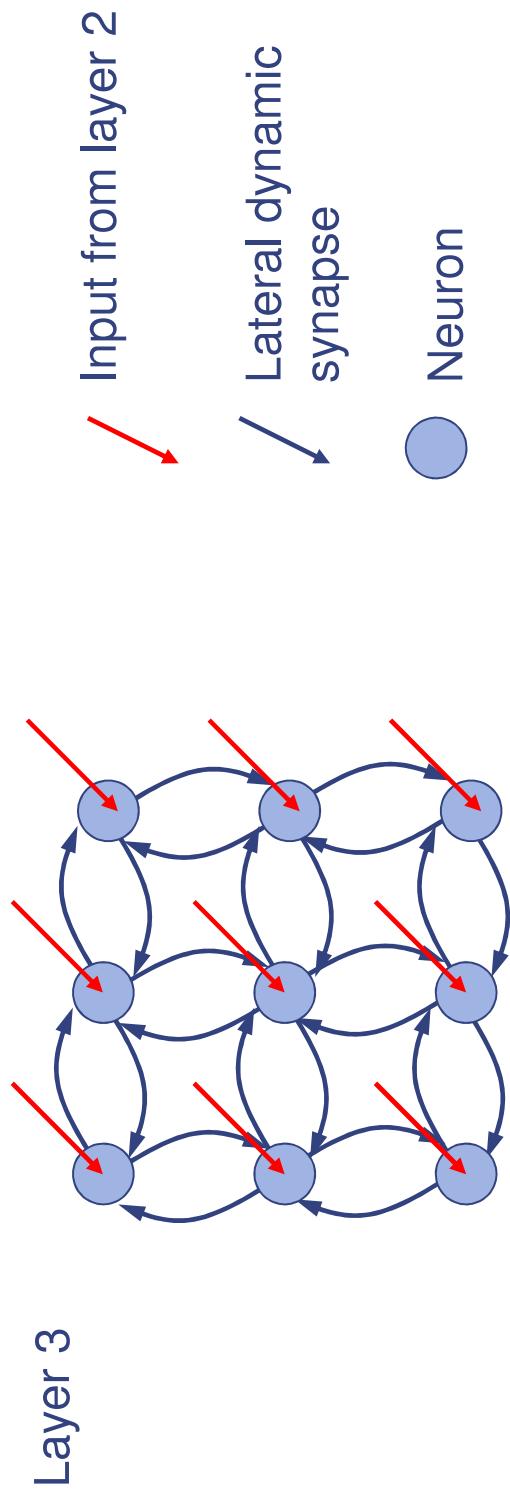
- $U(t) \geq \theta$: (I) reset U
 (II) fire for $t_d = 1ms$



Experiment: Synchronization

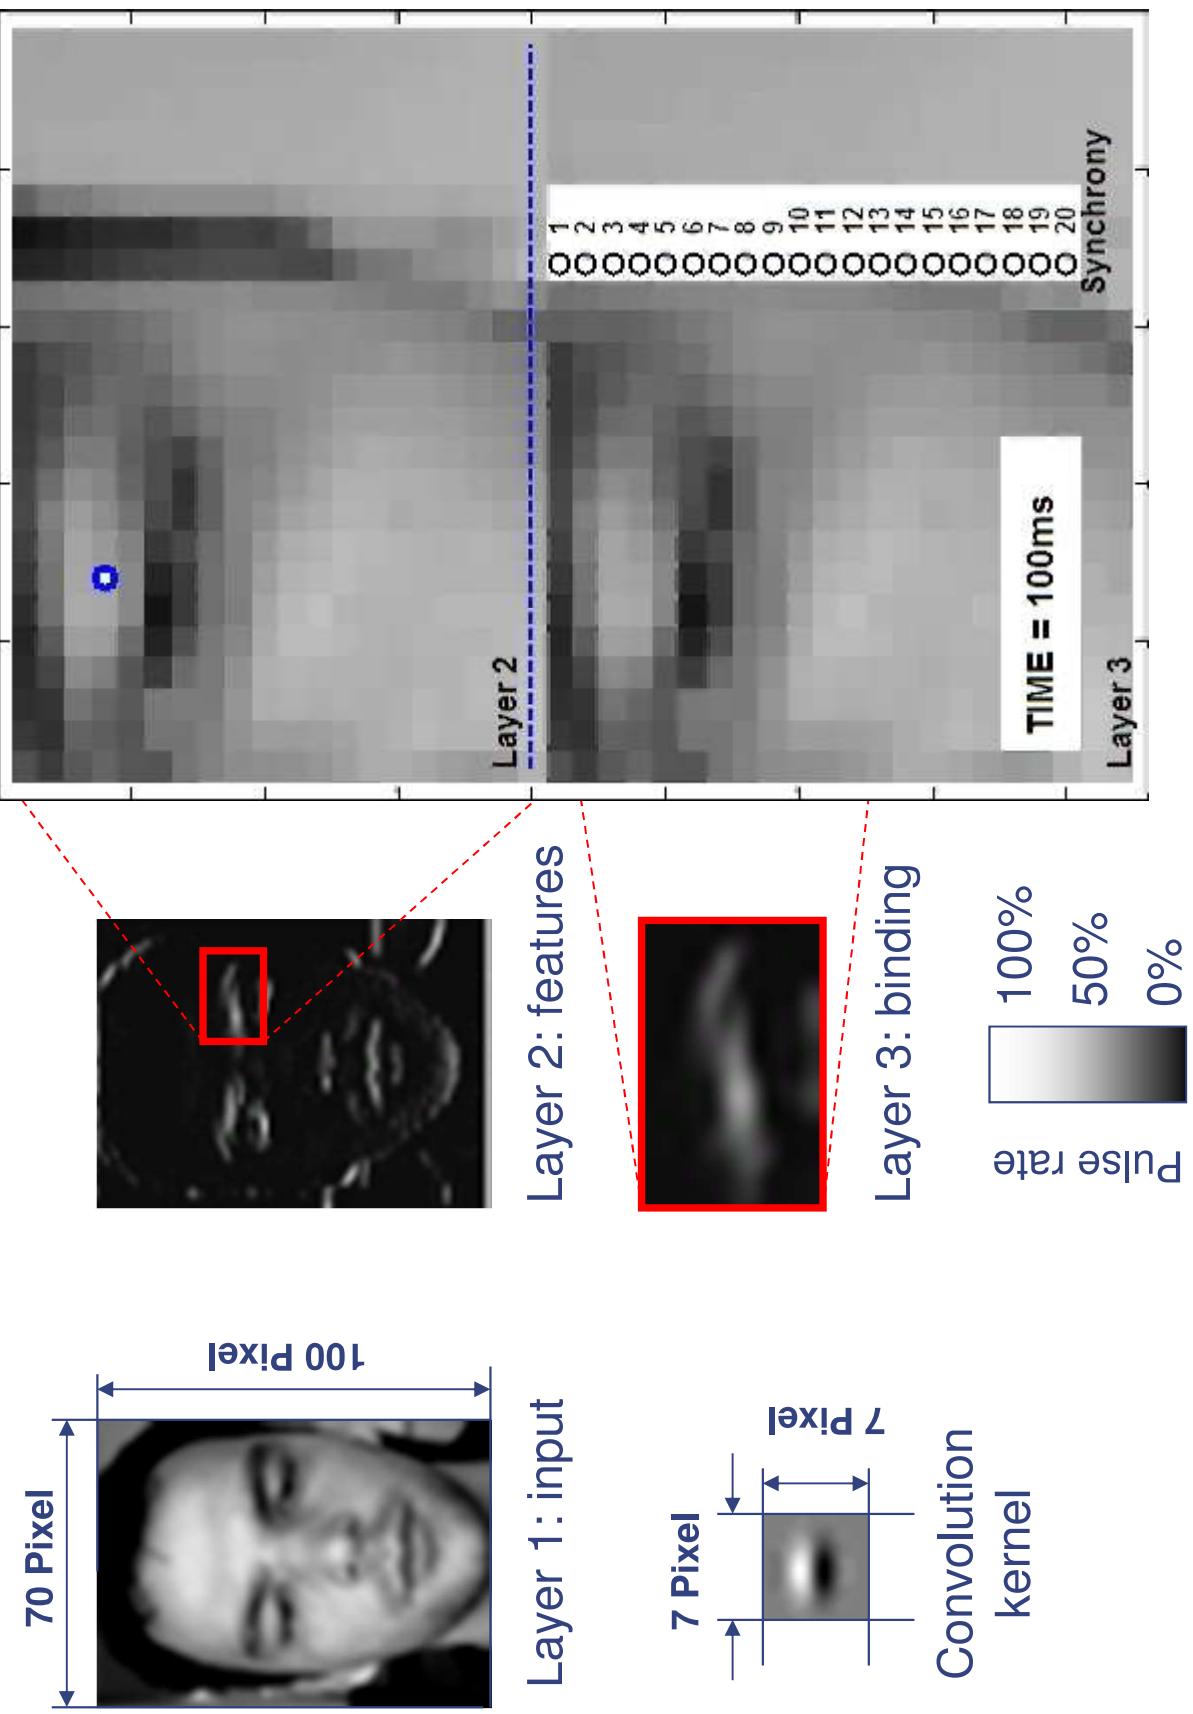


A: Experimental setup, architecture with 3 layers



B: Synchronization layer, network for lateral synchronization

Experiment: Binding by Synchronization



3.6 Codierung der Neuronenaktivität

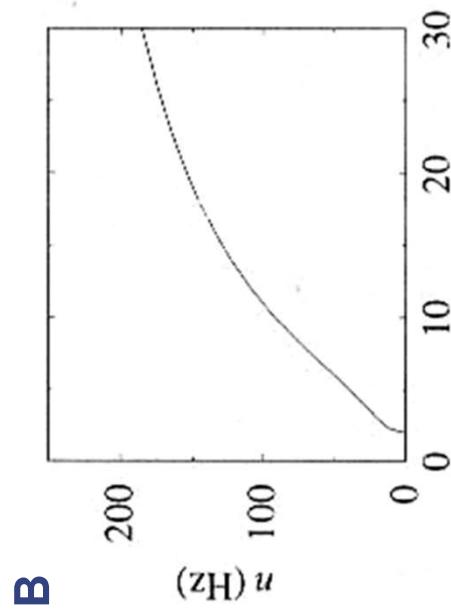
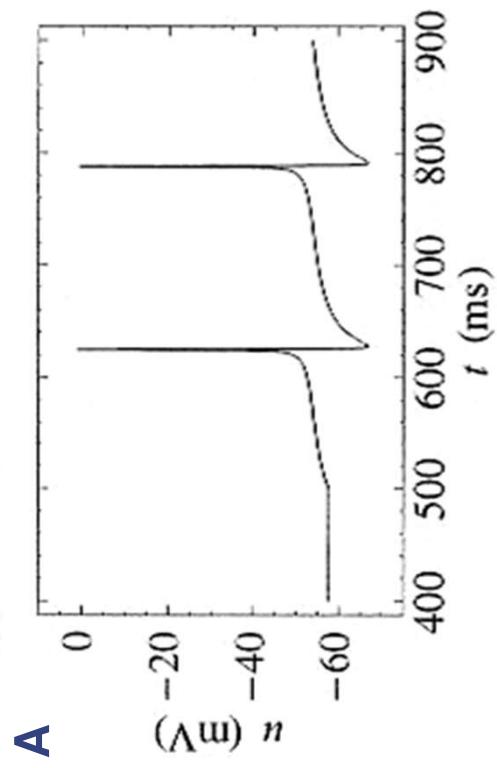
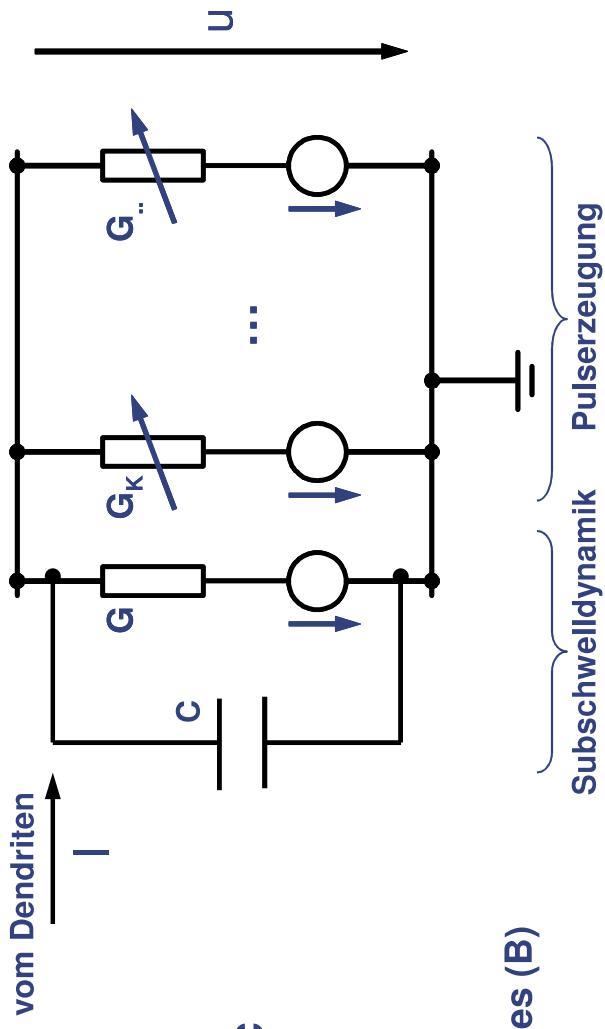
- Typ 1 Neuron

- Experiment:

- (I) Strominjektion auf Membran C
- (II) Gleichstrom

- Reaktion:
Aktionspotentiale (A)

- Pulssrate in Abhängigkeit des Stromes (B)



A: Übertragungsfunktion

Informationsverarbeitung durch pulscodierte neuronale Netze

- Neuronen repräsentieren und übertragen Information durch Sequenzen von Spikes in Form von zeitlichen Pulsmustern

(a) „neural response function“

$$\rho^{(j)}(t) = \sum_{i=1}^n \delta(t - t_i) \quad t_i : \text{Feuerzeitpunkt}$$

(b) „Sendesignal“ (1 Neuron)

$$X^{(j)}(t) = \sum_{i=1}^n \chi(t - t_i) - \chi(t - t_i + t_d)$$

(c) „Sendesignal“ (n Neurone)
„Zerlegungsvektor“

$$X(t) = [X^{(1)}(t), X^{(2)}(t), \dots, X^{(n)}(t)]$$

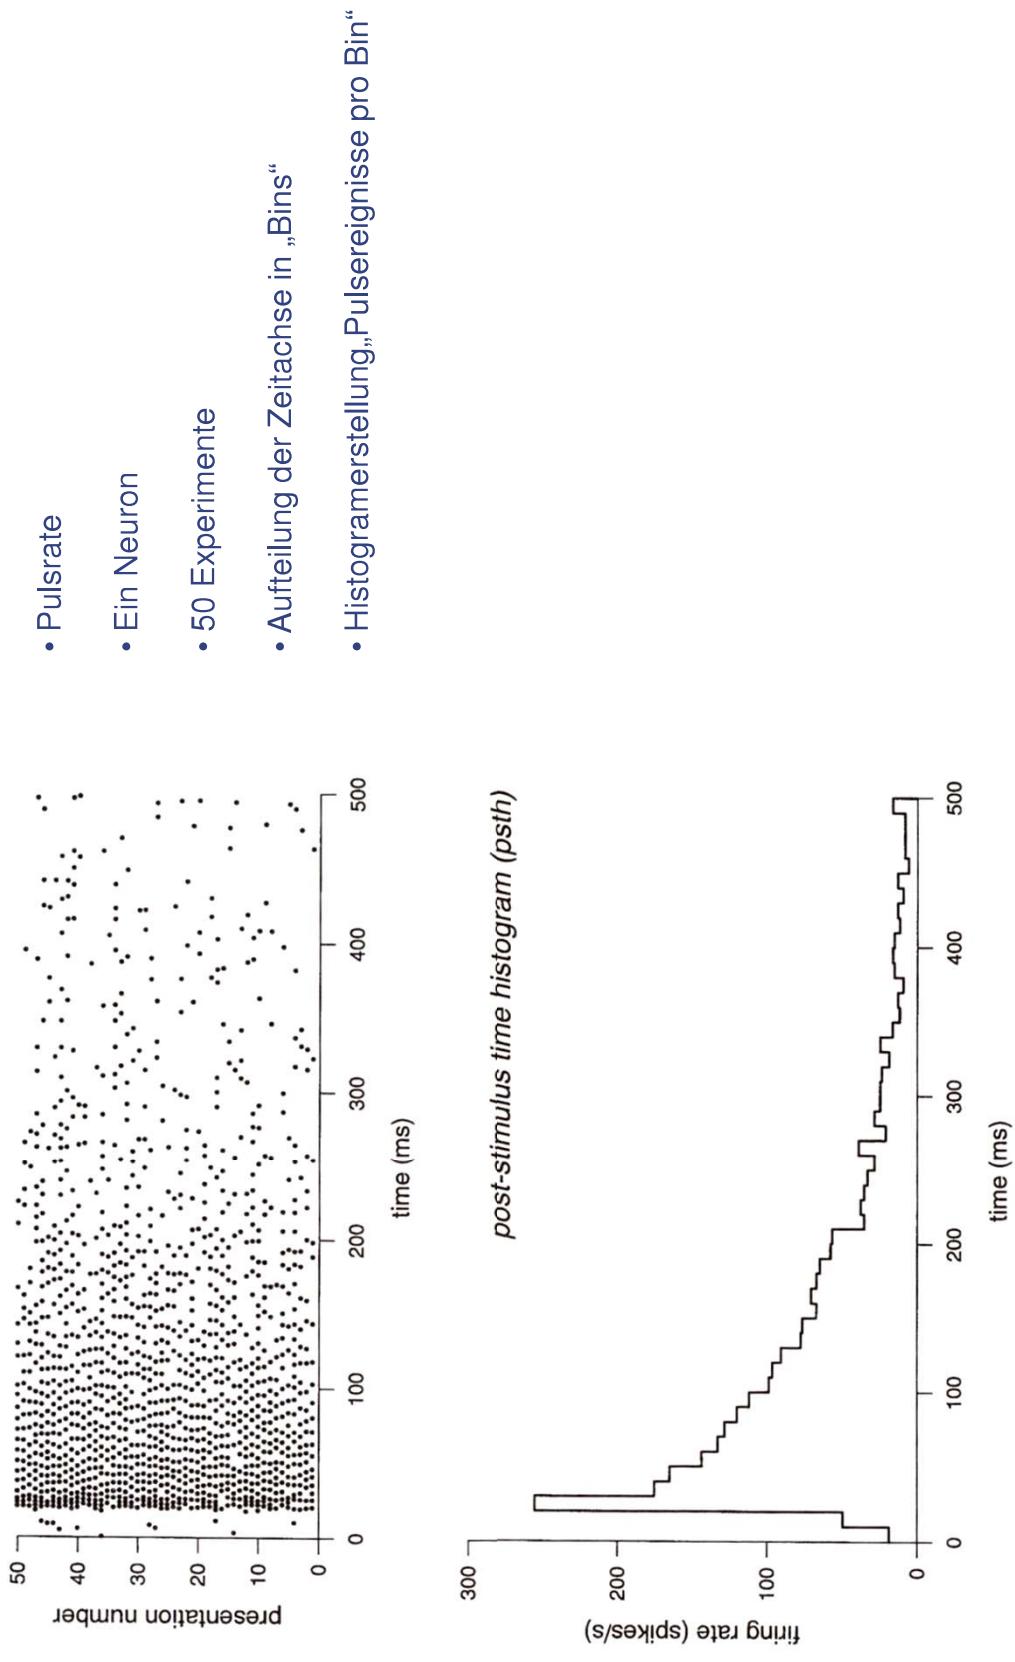
- Informationsverarbeitung:

Festlegung bzw. Analyse der Input-Output-Relation („Funktion“) von Netzwerken

- Hypothese: Die Input-Output-Relation ist für gegebenen Stimulus $S(t)$ eines Netzwerkes durch die (ggf. unendliche) zeitliche Abfolge der Pulsmuster $X(t)$ vollständig bestimmt.

- „time to first spike“, „rank order coding“, „rate codes“ ...

- Die klassischen theoretischen Arbeiten drücken die Aktivität von pre- und postsynaptischen Neuronen durch *Pulsraten* aus, d.h. als kontinuierliche Funktionen, die z.B. aus der *zeitlichen Mittelung* von aufeinanderfolgenden Spikes entstehen.



- Modellierung der Pulsaktivität durch statistische Größen

(I) *Spike-Count-Rate*

$$r^{(i)} = \frac{1}{T} \int_0^T \rho^{(i)}(\tau) d\tau$$

(II) *Firing Rate*

$$r^{(i)}(t) = \frac{1}{\Delta t} \int_t^{t+\Delta t} <\rho^{(i)}(\tau)> d\tau$$

(III) *Average Firing Rate*

$$< r > = \frac{1}{T} \int_0^T r^{(i)}(\tau) d\tau$$

(IV) *Correlation*

$$C^{(i,j)}(\tau) = \frac{1}{T \cdot t_d} \int_0^T X^{(i)}(t) \cdot X^{(j)}(t-\tau) dt$$

(V) *Pulse Rate*

$$\pi^{(i)} = C^{(i,i)}(0)$$

Empirisch !



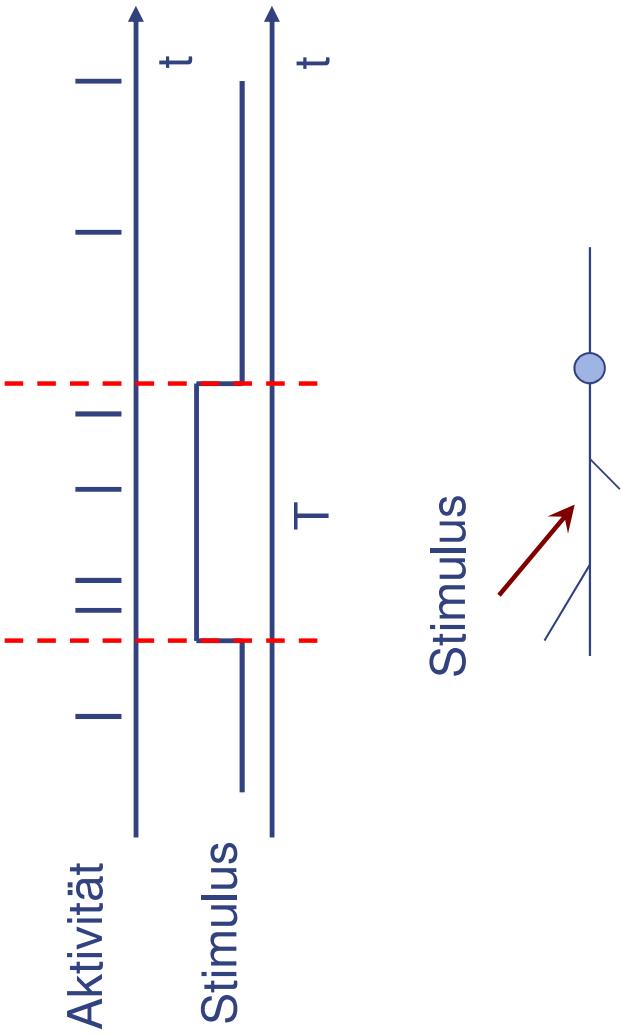
Die Pulsrate

- + I-f Zusammenhang gilt streng nur für DC-Erregung
- + eine dynamische Erregung resultiert i.d.R. in komplexeren Pulsmustern
- + führt zu unterschiedlichen Definitionen der Pulsrate (als statistische Größe)

(1) Rate wird durch Spike-Zähler definiert (Zeitmittel für ein Neuron)

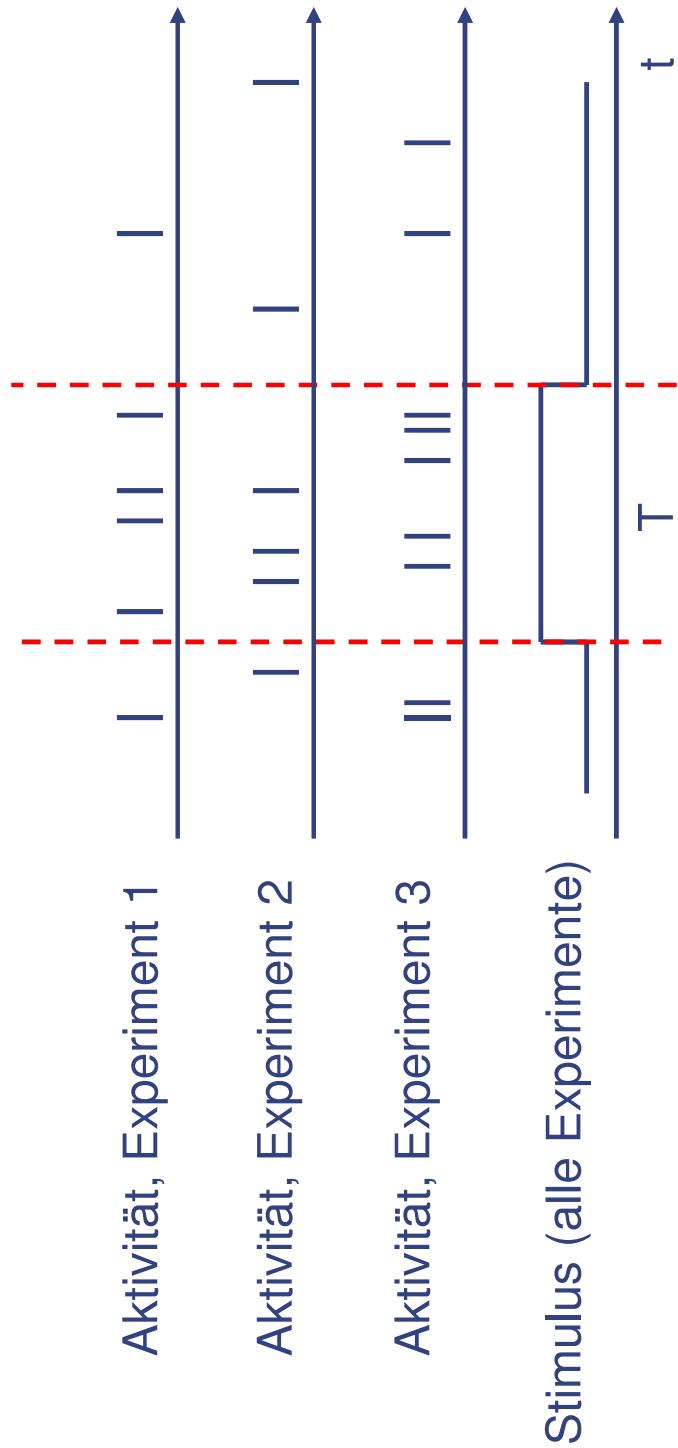
$$X = \frac{n_{SP}(t; t + T)}{T}$$

T: Meßintervall
n_{SP}: Anzahl der Spikes in T



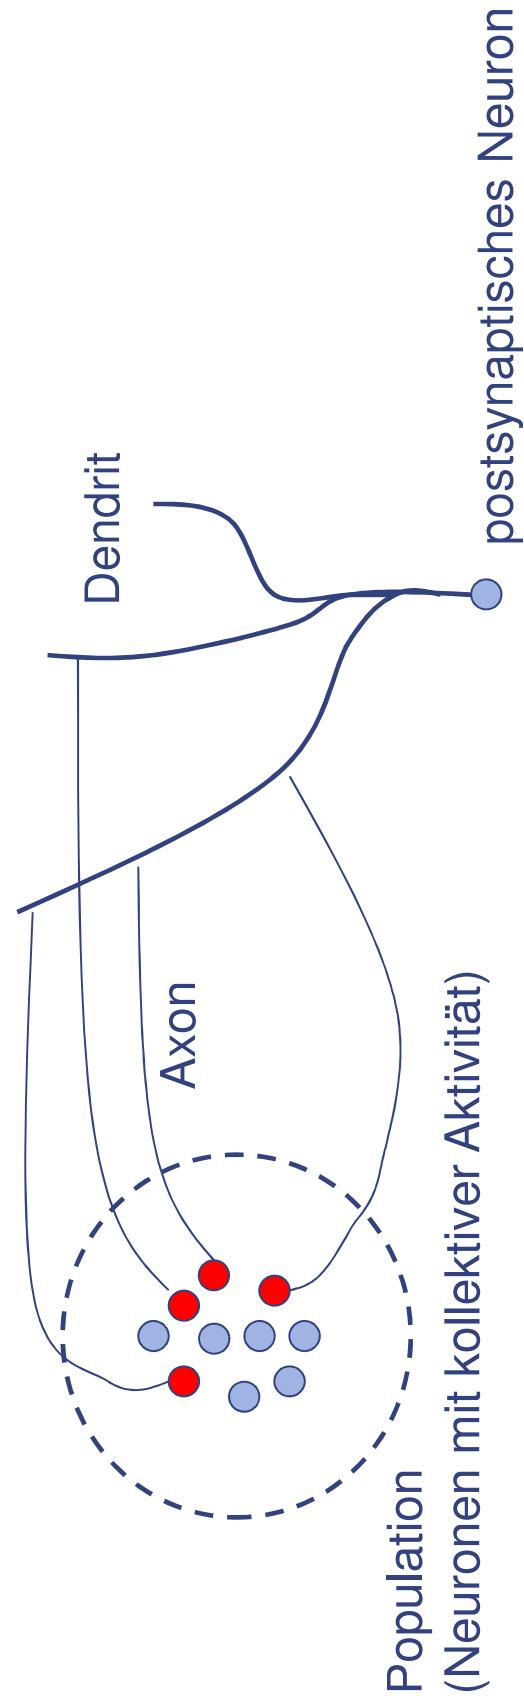
(2) Rate wird über Spike-Dichte gemessen (Mittelwert über mehrere Experimente, 1 Neuron)

$$X = \frac{1}{T} \cdot \frac{1}{K} \cdot n_{SP,K}(t; t+T)$$



(3) Aktivität einer Neuronen-Population (Mittelung über mehrere Neuronen)

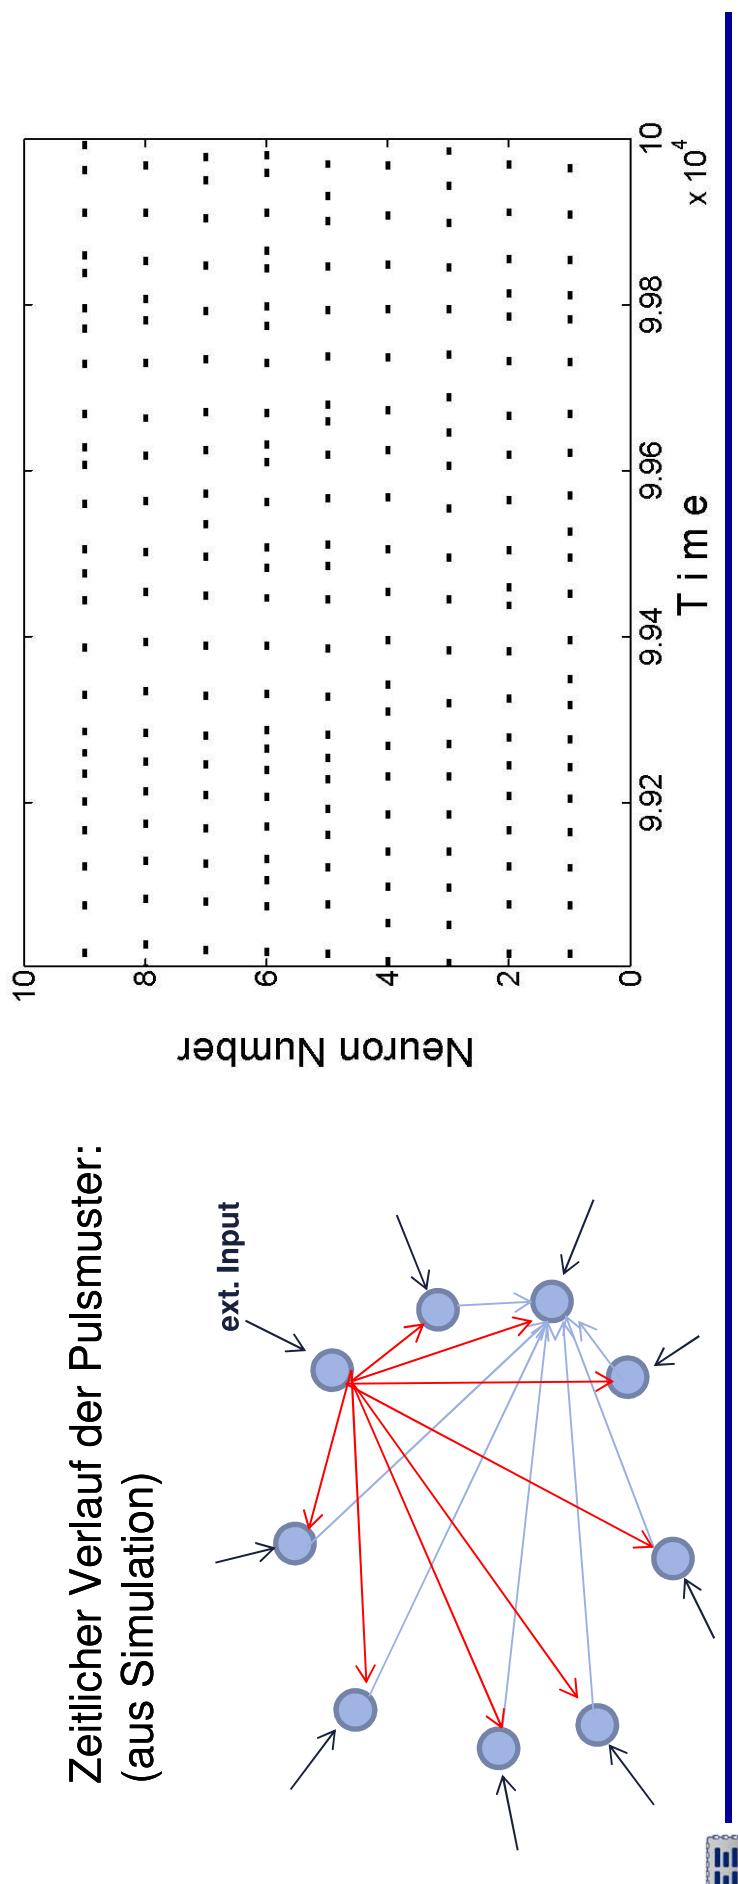
$$X = \frac{1}{T} \cdot \frac{1}{N_p} \cdot n_{SP, N_p}(t; t+T) \quad N_p: \text{Umfang der Population}$$



Beispiel: Netz aus 9 gekoppelten IAF Neuronen

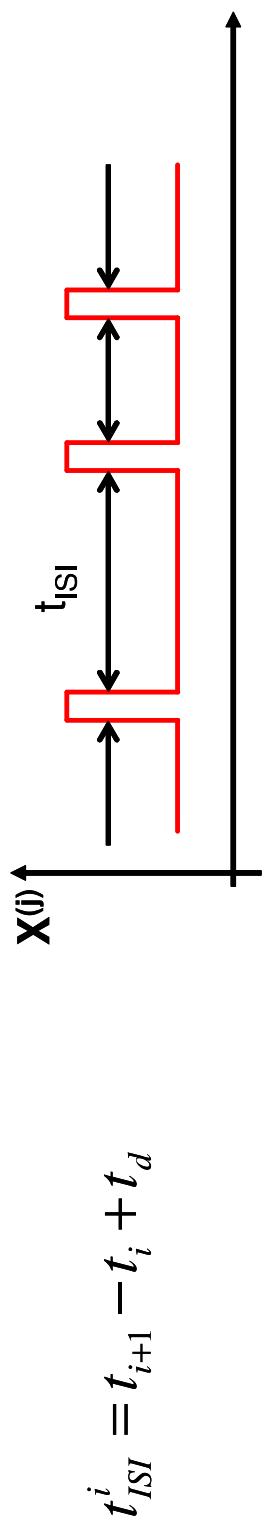
- Membrangleichung: $\frac{d}{dt}u_K = \sum_L W_{KL} \cdot \chi(X^{(L)}) + W_{K0} \cdot I_0$ $u_{rest} = u_{reset} = 0V$
- Refraktärzeit, Schwelle: $t_d = 1ms$, $\theta = 1mV$

- W_{KL} : konstantes Kopplungsgewicht mit bestimmtem (zufällig gewähltem) Wert



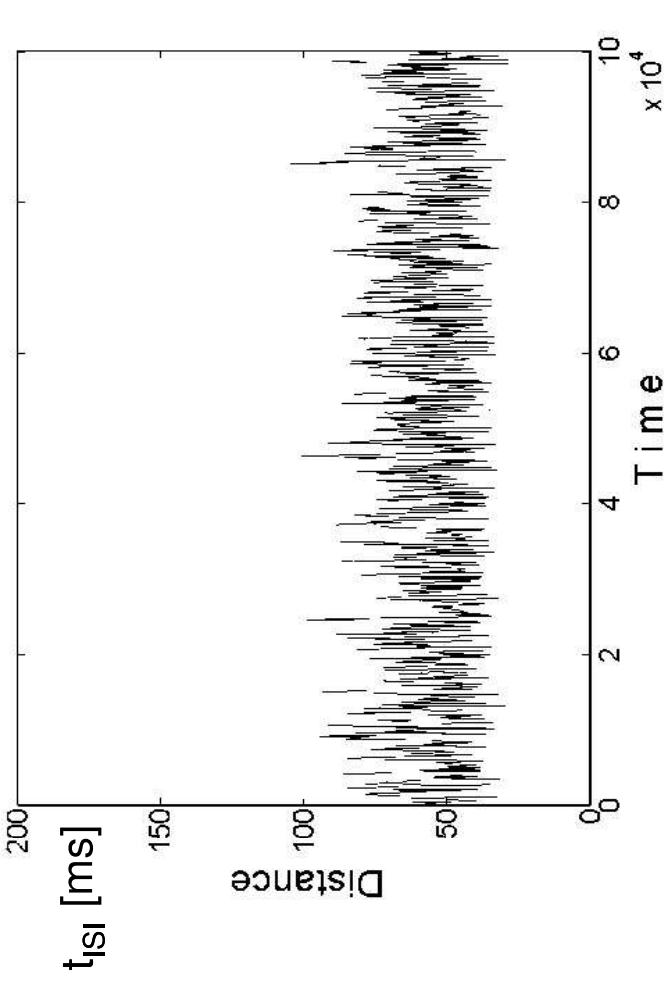
Beispiel: Netz aus 9 gekoppelten IAF Neuronen

- Messung des *Interspike-Interval/s* t_{ISI} für ein ausgewähltes Neuron



- Ergebnis:

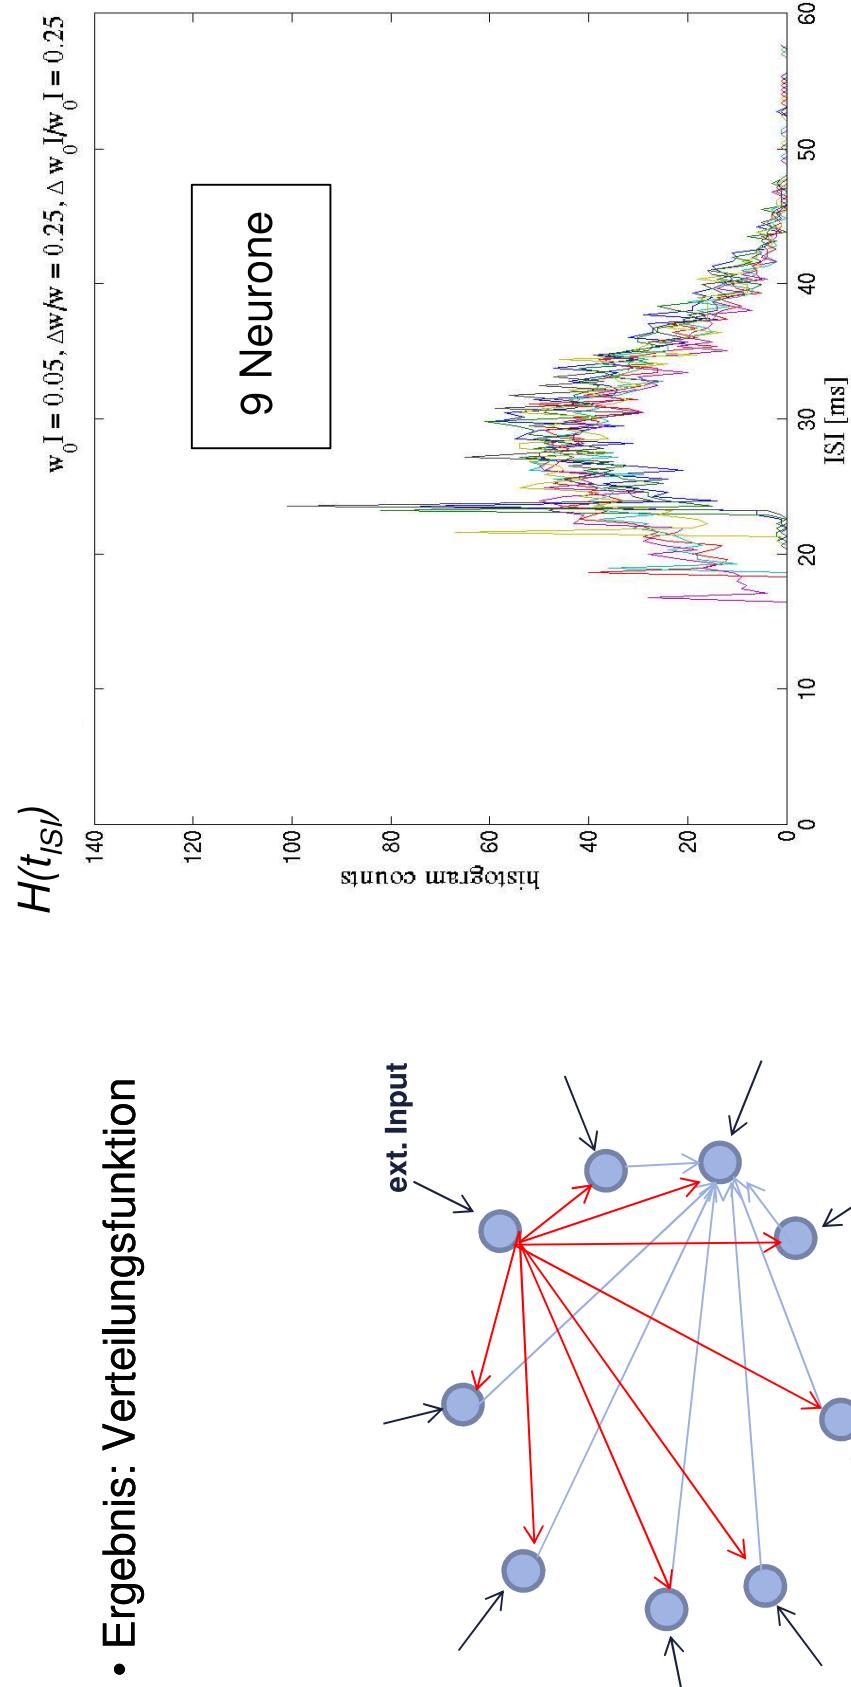
der Verlauf des Interspike-Intervalls weist einen *statistischen* Verlauf auf (phänomenologisch).
Man beachte: Es handelt sich um ein *deterministisches* System.



Beispiel: Netz aus 9 gekoppelten IAF Neuronen

- Aufzeichnung des Histogramms $H(t_{ISI})$ der Pulssabstände (Eliminierung der Information über die zeitliche Abfolge):

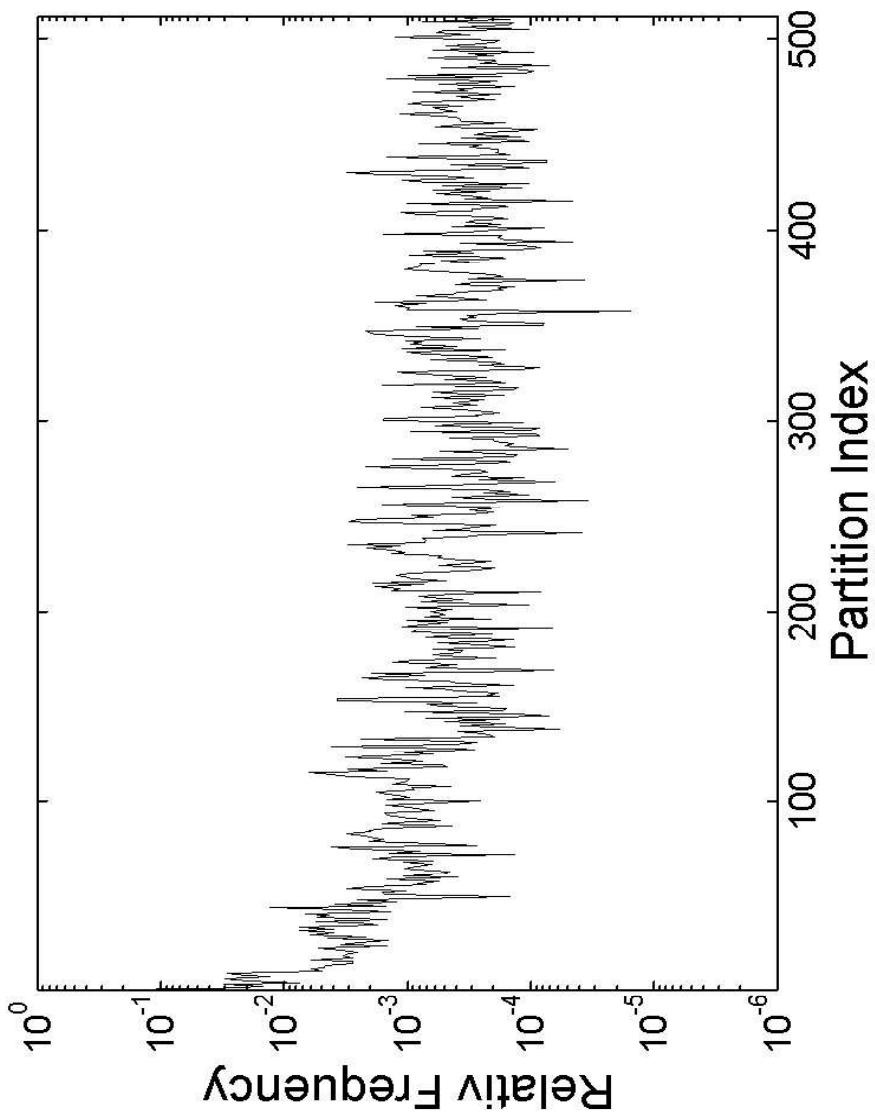
„Welcher Pulssabstand kommt wie häufig vor“



- Ergebnis: Verteilungsfunktion

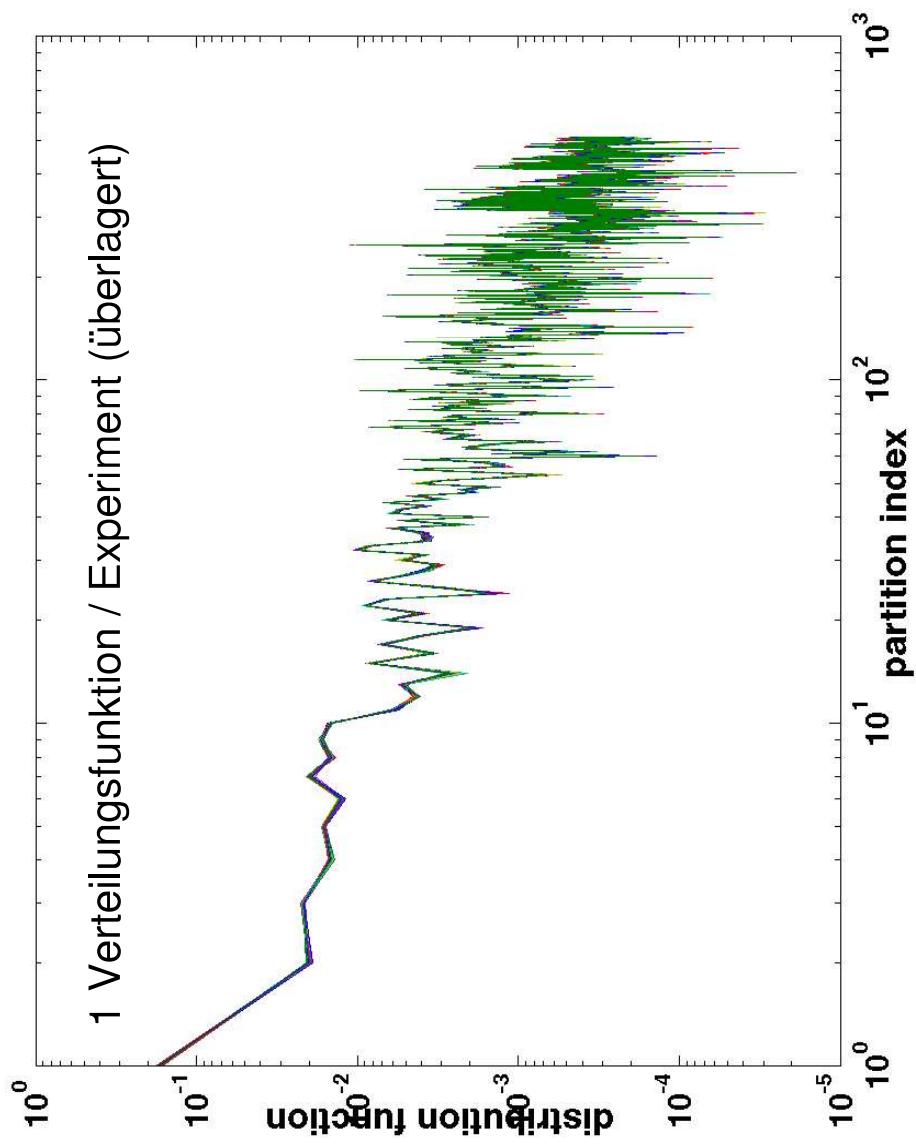
Beispiel: Netz aus 9 gekoppelten IAF Neuronen

- Verteilungsfunktion der Zerlegungsvektoren ($n=9$, 512 verschiedene Zerlegungsvektoren)



Beispiel: Netz aus 9 gekoppelten IAF Neuronen

- Verteilungsfunktion für verschiedene Anfangsbedingungen (100 verschiedene Anfangsbedingungen): Resultat: identische Verteilungsfunktionen

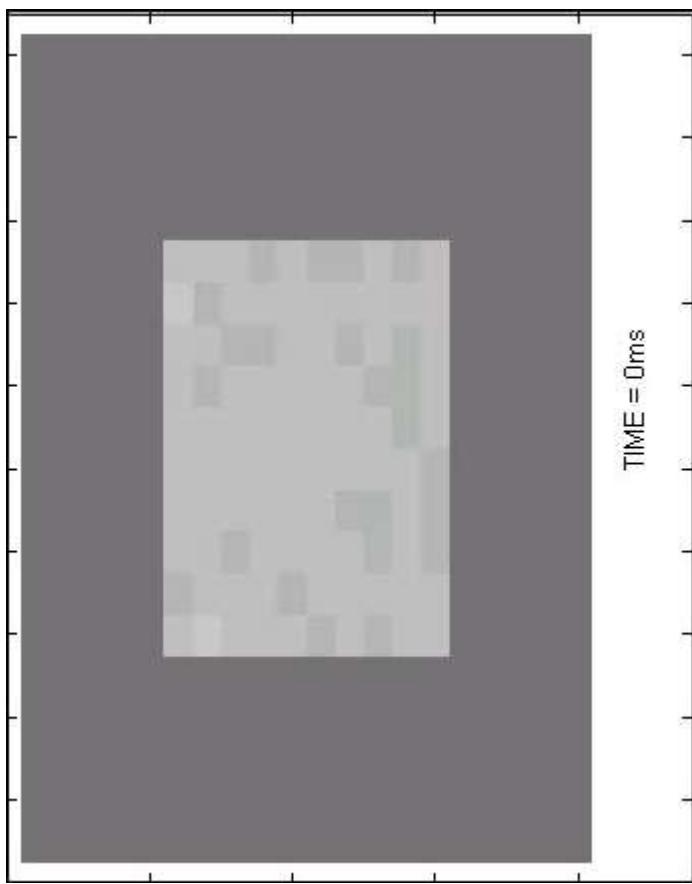


Beispiel: 20×20 gekoppelte IAF-Neuronen

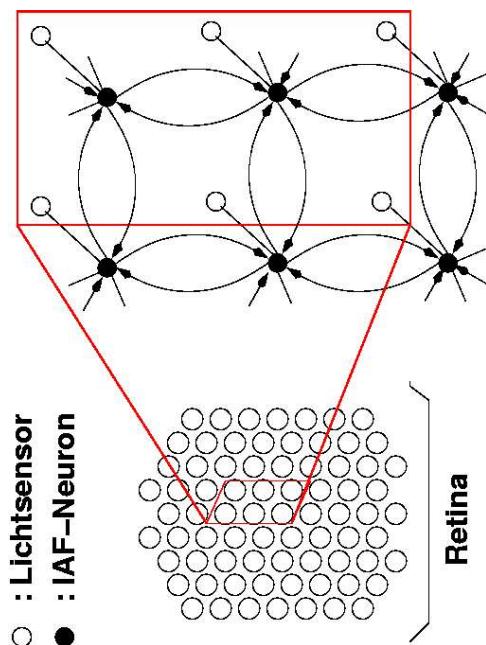
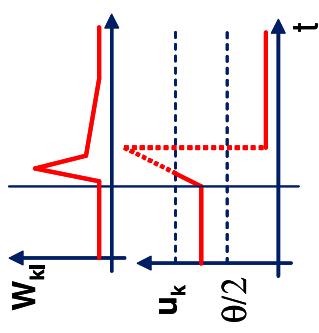
- lokale (nächstnachbarliche) Kopplung der Neuronen mit dynamischen Synapsen

$$\tau \cdot \frac{d}{dt} W_{KL} = -W_{KL} + \tau \cdot \mu \cdot \left(u_K(t) - \frac{\theta}{2} \right) \cdot \chi(X^{(L)})$$

[Heittmann, Ramacher 2002]



20×20 Neurone, 10% Noise

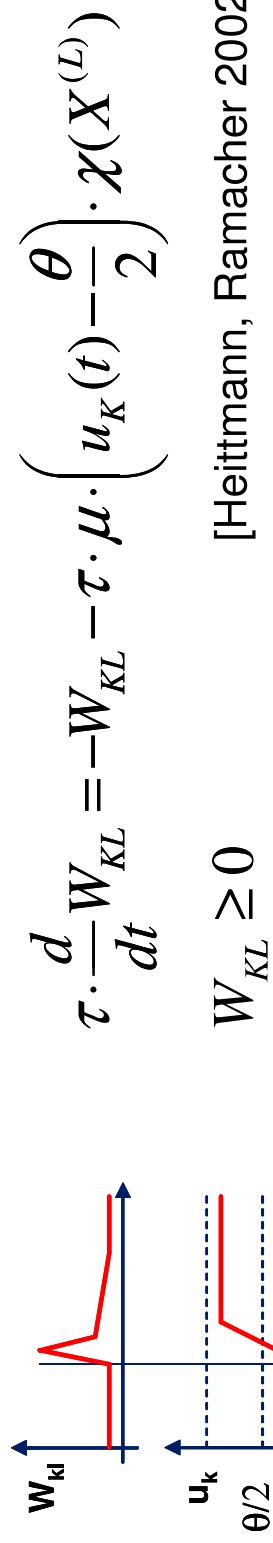


- Ergebnis: Pulswellen, eingeschränkter Zustandsraum

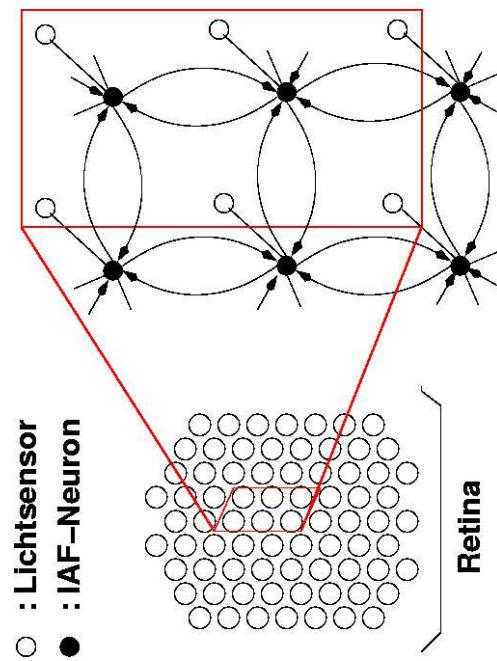
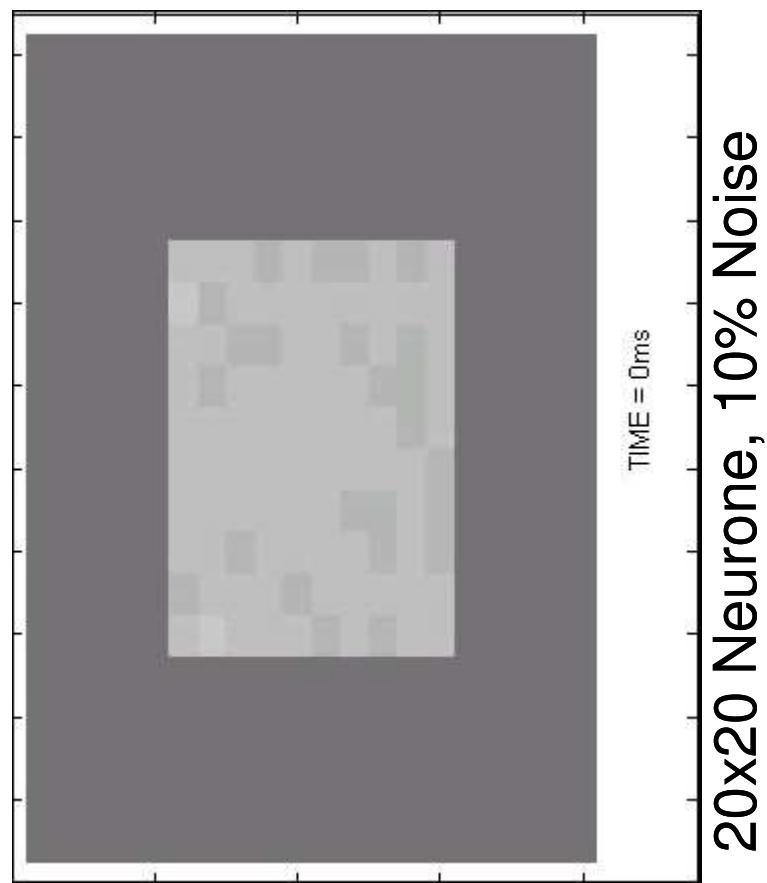


Beispiel: 20×20 gekoppelte IAF-Neuronen

- lokale (nächstnachbarliche) Kopplung der Neuronen mit dynamischen Synapsen



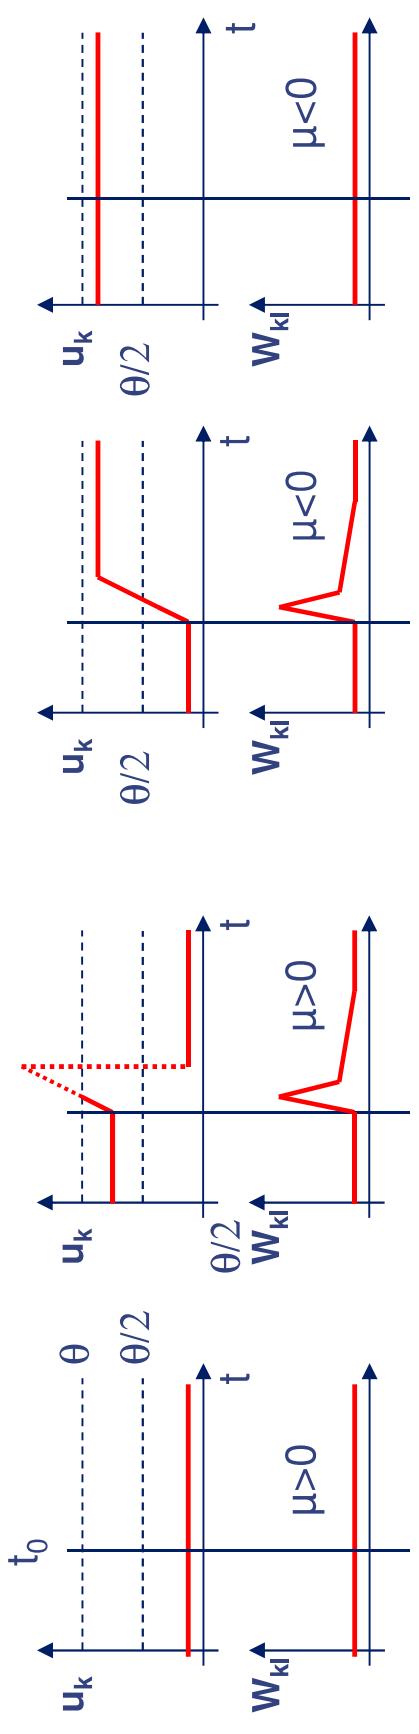
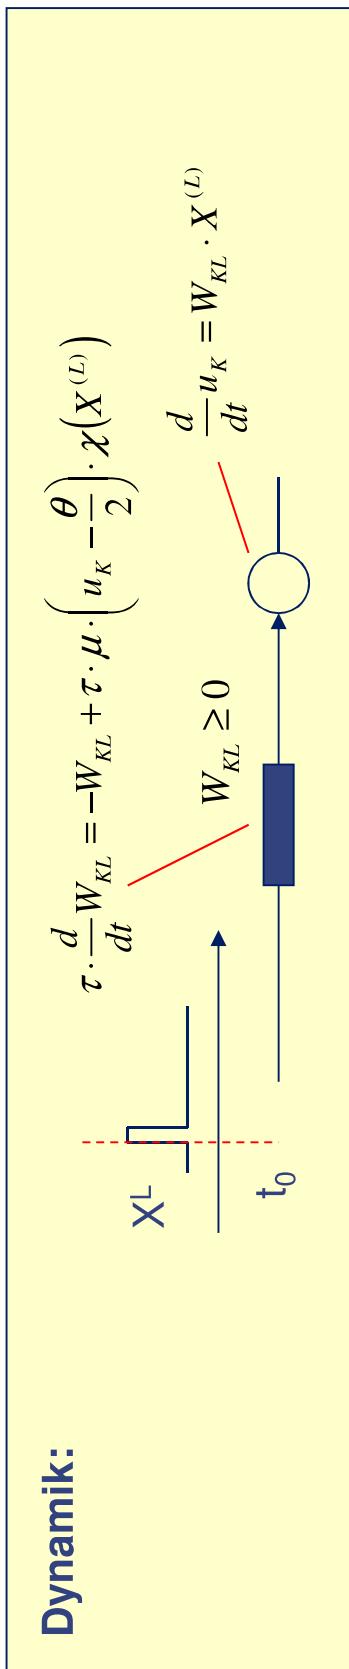
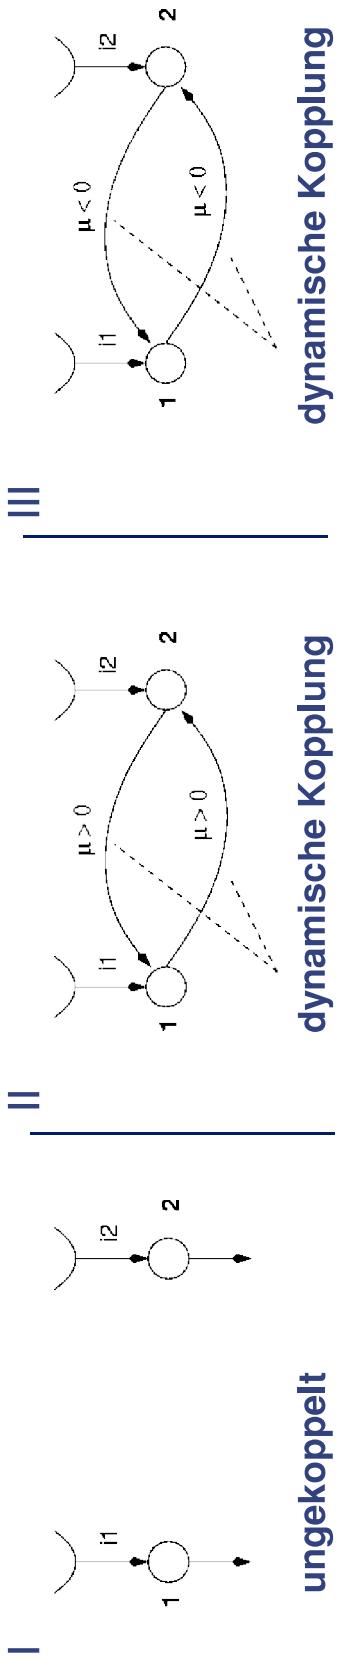
[Heittmann, Ramacher 2002]



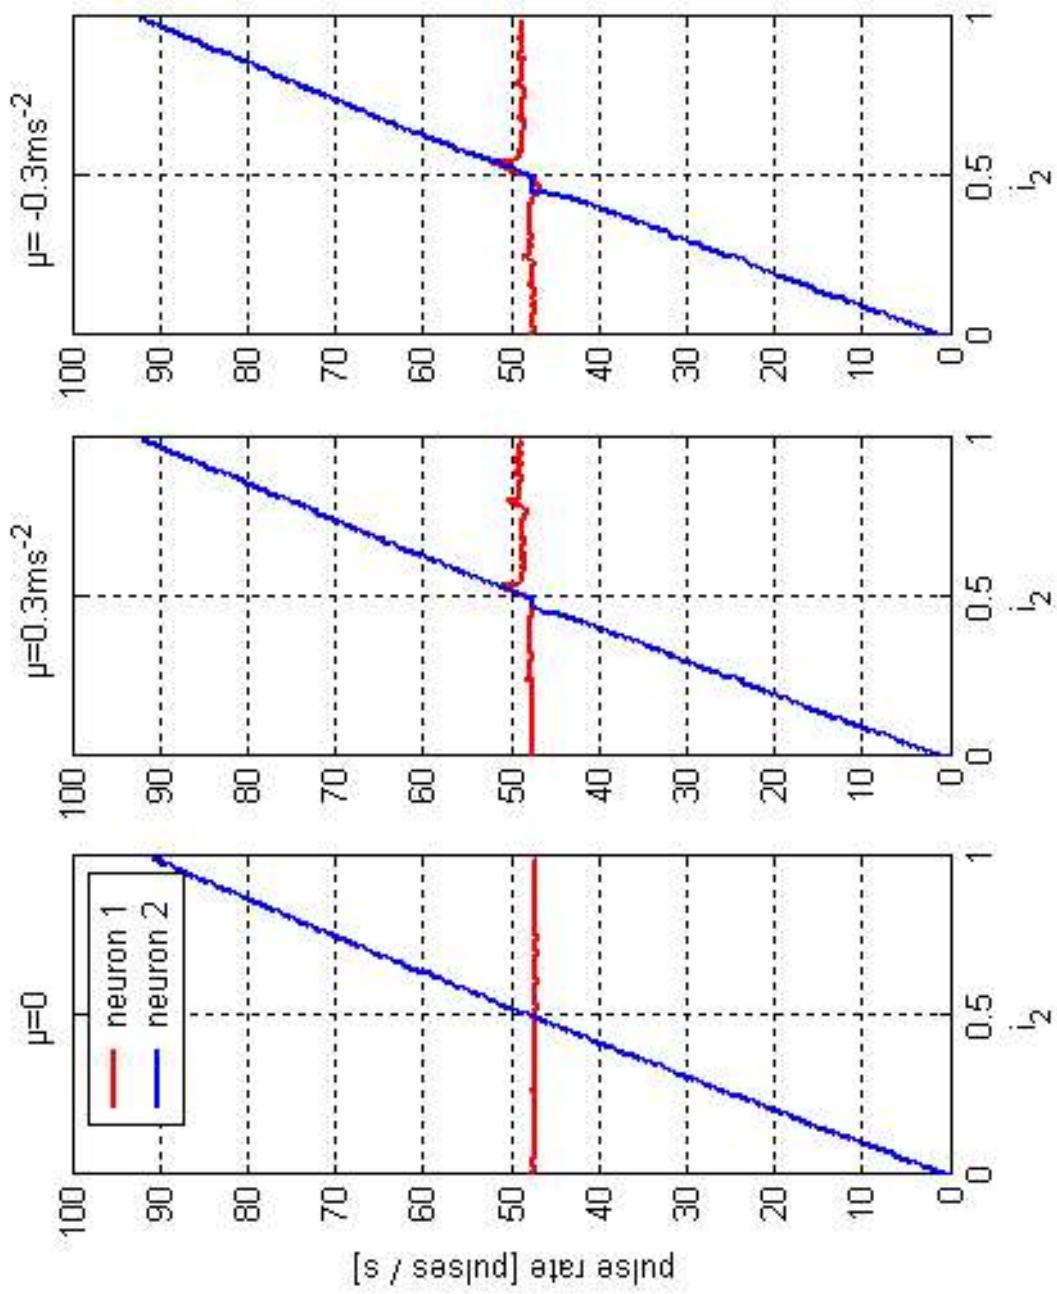
- Ergebnis: *ungeordnetes Feuern*, weiterhin eingeschränkter Zustandsraum



Drei Experimente mit dynamischen Synapsen



Pulsrate

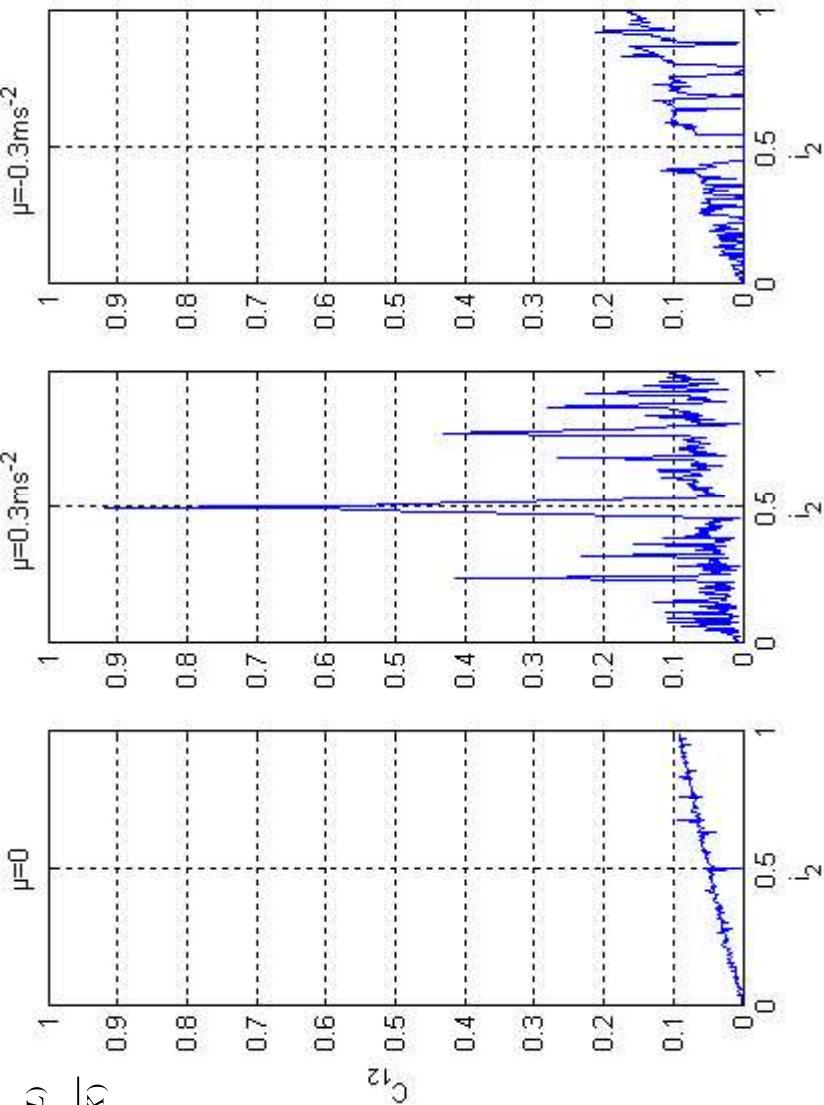


$$\begin{aligned}
 i_1 &= 0.5 \\
 \Theta &= 1 \\
 W_{K0} &= 0.1 \\
 t_d &= 1 \text{ ms} \\
 |\mu| &= 0.3 \text{ ms}^{-2} \\
 \tau &= 0.1 \text{ ms} \\
 T &= 20 \text{ s}
 \end{aligned}$$

- Ergebnis: die Pulsrate ist nahezu unabhängig vom Kopplungstyp

Korrelation

$$\bar{C}^{(K,K)} = \frac{C^{(K,L)}}{C^{(K,K)}}$$



$i_1 = 0.5$
 $\Theta = 1$
 $W_{K0} = 0.1$
 $t_d = 1 \text{ ms}$
 $|\mu| = 0.3 \text{ ms}^{-2}$
 $\tau = 0.1 \text{ ms}$
 $T = 20 \text{ s}$

- Ergebnis: die Correlation wird signifikant vom Kopplungstyp bestimmt

Informationsverarbeitung durch pulscodierte neuronale Netze

- Unterscheidung

- (a) ergodische Netzwerke

Ia: für jeden Stimulus $S(t)$ gibt es einen endlichen Zeitpunkt, in dem das System einen gegebenen Zustand einnimmt. Das System durchläuft somit sämtliche denkbaren Zustandsvektoren.

und

IIa: die Zerlegungsvektoren werden in beliebiger Reihenfolge durchlaufen

Input-Output-Relation kann durch Histogramm der Zerlegungsvektoren charakterisiert werden.

- (b) nichtergodische Netzwerke

IIb: das System durchläuft nicht alle denkbaren Zustände

oder

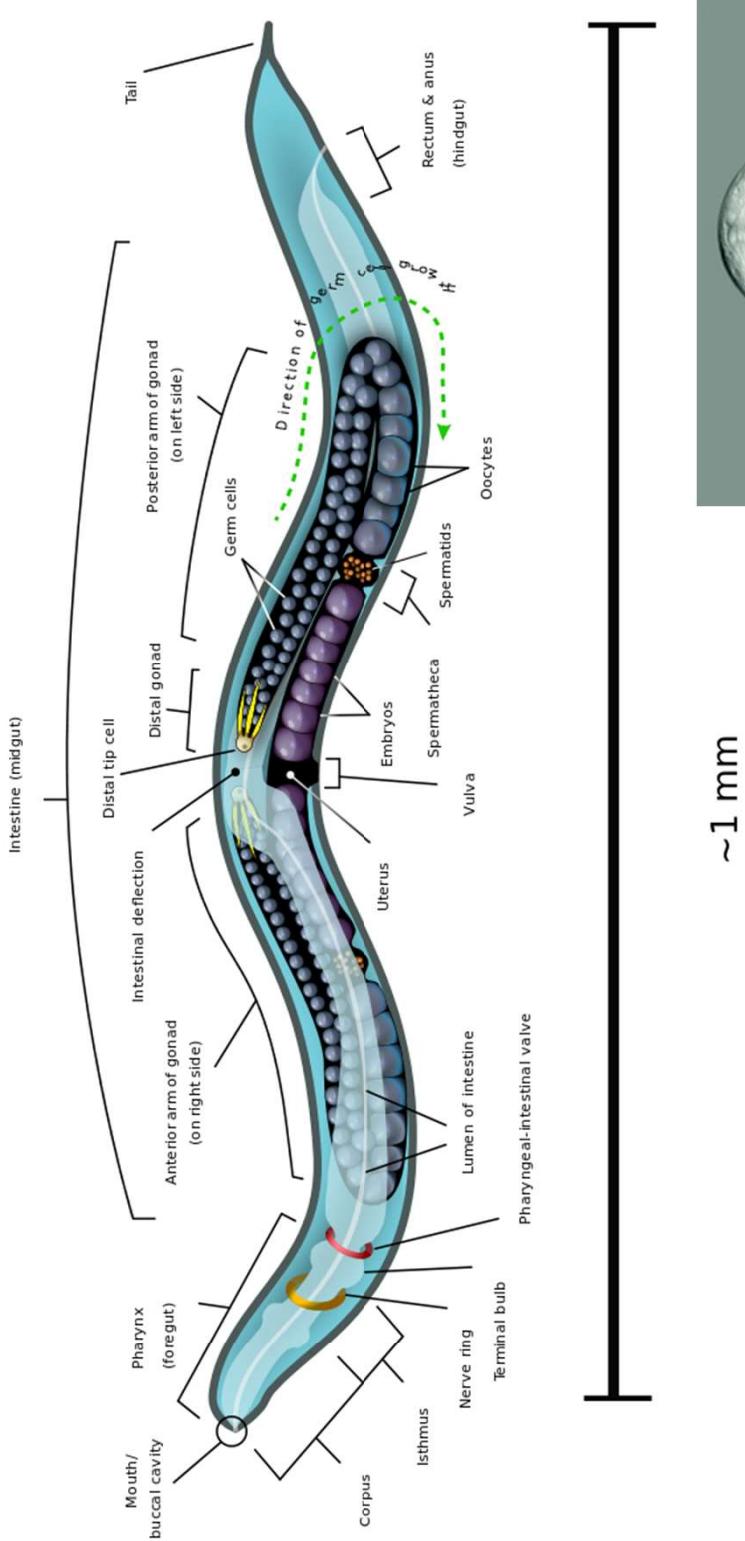
IIb: die Zerlegungsvektoren werden in fester Reihenfolge durchlaufen



3.7 Netzwerke und Kopplungen

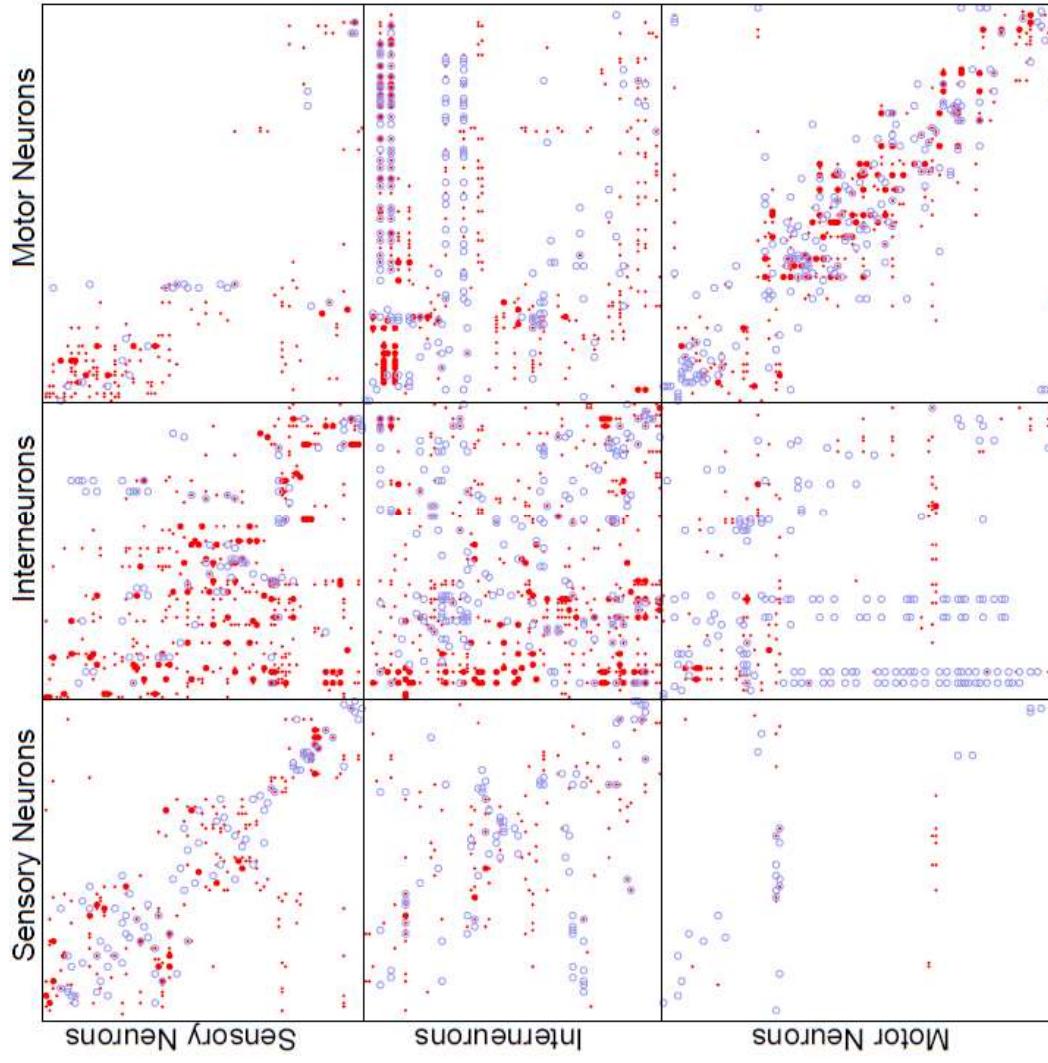


Caenorhabditis elegans



- genome sequenced in 2012
- complete connectome known
 - e.g. Hermaphrodite: 302 Neurons

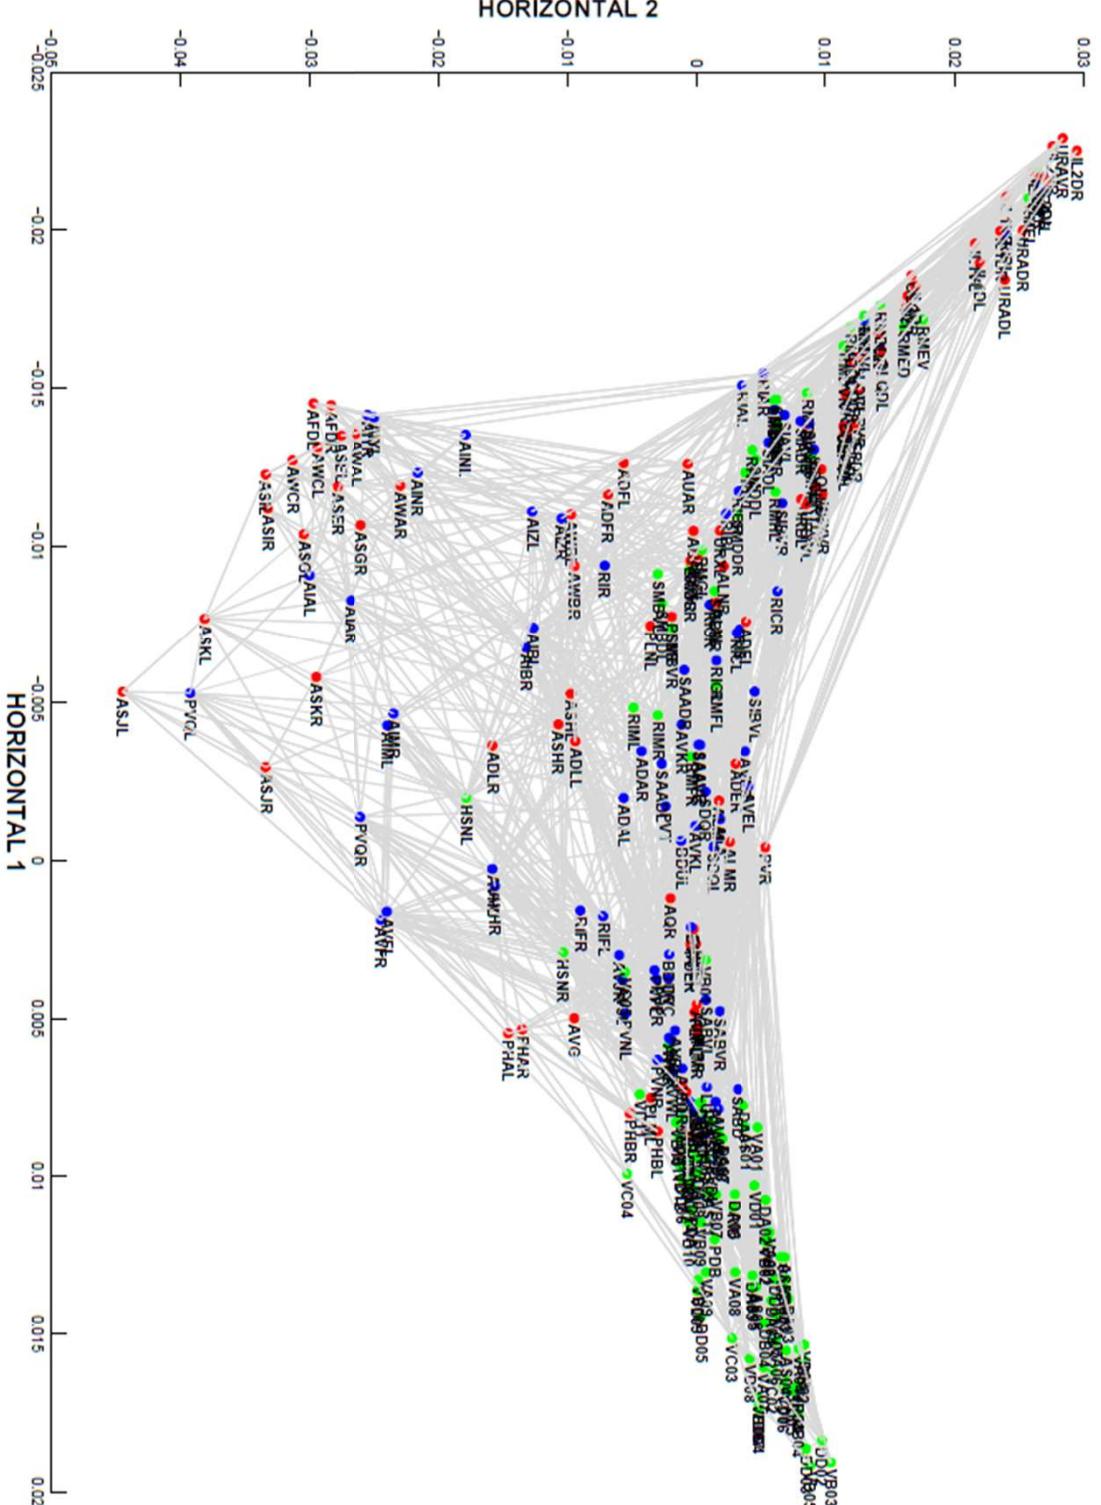
Caenorhabditis elegans Neuronal Network



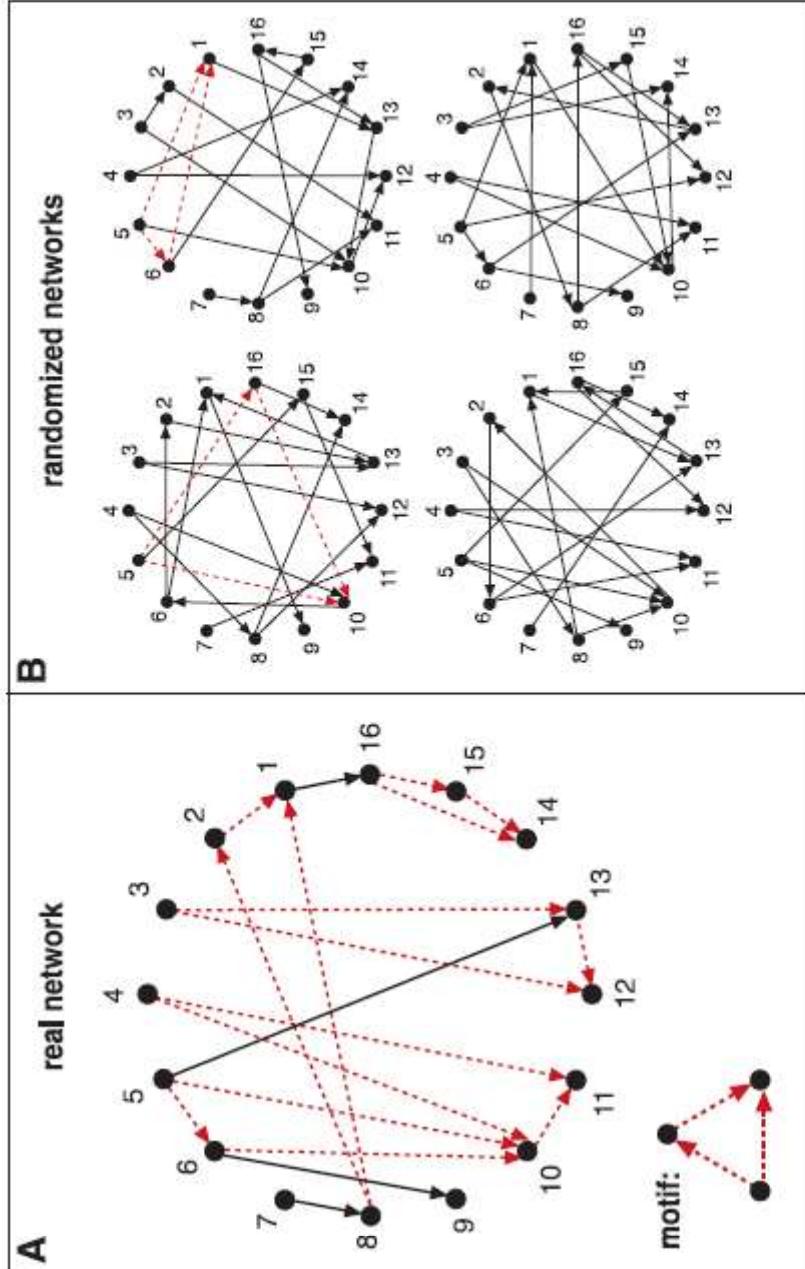
- gap-junctions (blue) and chemical synapses (red)

Caenorhabditis elegans Wiring Diagramm

L.R.Varshney, B.L.Chen, E.Paniagua, D.H.Hall, D.B.Chklovskii,
 „Structural Properties of the *Caenorhabditis elegans* Neuronal
 Network“, 2009



Frage: was sind typische Verbindungs muster?



*) Schematic view of network motif detection. Network motifs are patterns that recur much more frequently (A) in the real network than (B) in an ensemble of randomized networks. Each node in the randomized networks has the same number of incoming and outgoing edges as does the corresponding node in the real network. Red dashed lines indicate edges that participate in the feedforward loop motif, which occurs five times in the real network.

*) Network Motifs: Simple Building Blocks of Complex Networks R. Milo, S. Shen-Orr, S. Itzkovitz, N. Kashtan, D. Chklovskii, U. Alon

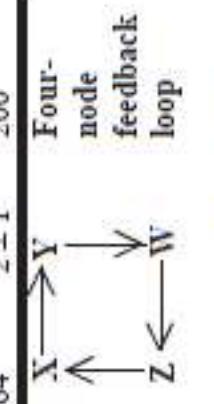
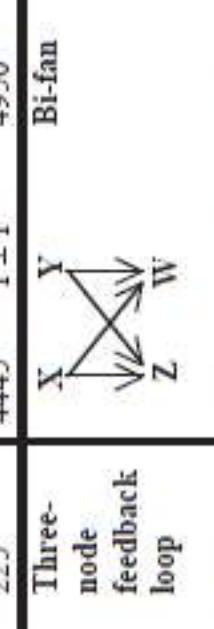
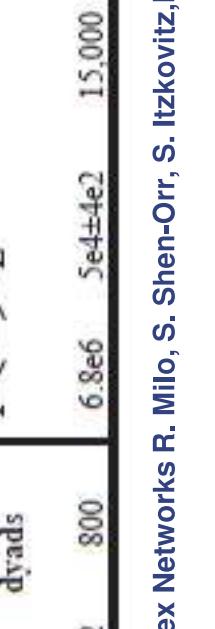
Motifs*) (I)

Network	Nodes	Edges	N _{real}	N _{rand} ± SD	Z score	N _{real}	N _{rand} ± SD	Z score	N _{real}	N _{rand} ± SD	Z score
Gene regulation (transcription)											
<i>E. coli</i>	424	519	40	7 ± 3	10	203	47 ± 12	13			
<i>S. cerevisiae*</i>	685	1,052	70	11 ± 4	14	1812	300 ± 40	41			
Neurons											
<i>C. elegans†</i>	252	509	125	90 ± 10	3.7	127	55 ± 13	5.3	227	35 ± 10	20
Food webs											
Little Rock	92	984	3219	3120 ± 50	2.1	7295	2220 ± 210	25			
Ythan	83	391	1182	1020 ± 20	7.2	1357	230 ± 50	23			
St Martin	42	205	469	450 ± 10	NS	382	130 ± 20	12			
Chesapeake	31	67	80	82 ± 4	NS	26	5 ± 2	8			
Coachella	29	243	279	235 ± 12	3.6	181	80 ± 20	5			
Skipwith	25	189	184	150 ± 7	5.5	397	80 ± 25	13			
B. Brook	25	104	181	130 ± 7	7.4	267	30 ± 7	32			

*) Network Motifs: Simple Building Blocks of Complex Networks R. Milo, S. Shen-Orr, S. Itzkovitz, N. Kashtan, D. Chklovskii, U. Alon



Motifs* (II)

Network	Nodes	Edges	N_{real}	$N_{\text{rand}} \pm \text{SD}$	Z score	N_{real}	$N_{\text{rand}} \pm \text{SD}$	Z score	N_{real}	$N_{\text{rand}} \pm \text{SD}$	Z score
Electronic circuits (forward logic chips)				Feed-forward loop		Bi-fan		Bi-parallel			
s15850	10,383	14,240	424	2 ± 2	285	1040	1 ± 1	1200	480	2 ± 1	335
s38584	20,717	34,204	413	10 ± 3	120	1739	6 ± 2	800	711	9 ± 2	320
s38417	23,843	33,661	612	3 ± 2	400	2404	1 ± 1	2550	531	2 ± 2	340
s9234	5,844	8,197	211	2 ± 1	140	754	1 ± 1	1050	209	1 ± 1	200
s13207	8,651	11,831	403	2 ± 1	225	4445	1 ± 1	4950	264	2 ± 1	200
Electronic circuits (digital fractional multipliers)				Three-node feedback loop		Bi-fan		Four-node feedback loop			
s208	122	189	10	1 ± 1	9	4	1 ± 1	3.8	5	1 ± 1	5
s420	252	399	20	1 ± 1	18	10	1 ± 1	10	11	1 ± 1	11
s838†	512	819	40	1 ± 1	38	22	1 ± 1	20	23	1 ± 1	25
World Wide Web				Feedback with two mutual dyads		Fully connected triad		Unlinked mutual dyad			
nd.edu§	325,729	1.46e6	1.1e5	2e3 ± 1e2	800	6.8e6	5e4±4e2	15,000	1.2e6	1e4 ± 2e2	5000

*) Network Motifs: Simple Building Blocks of Complex Networks R. Milo, S. Shen-Orr, S. Itzkovitz, N. Kashtan, D. Chklovskii, U. Alon

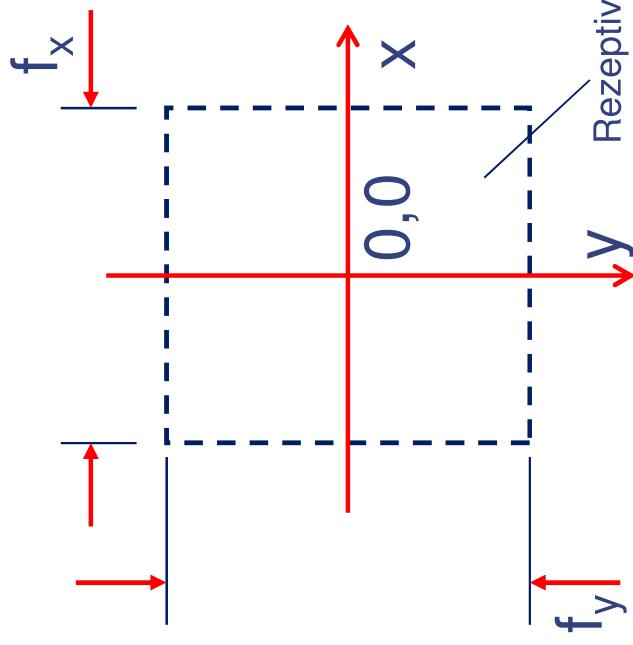


3.7.1 „Funktion“ von Verbindungen

Beispiel: Pulskodierte Merkmalsextraktion



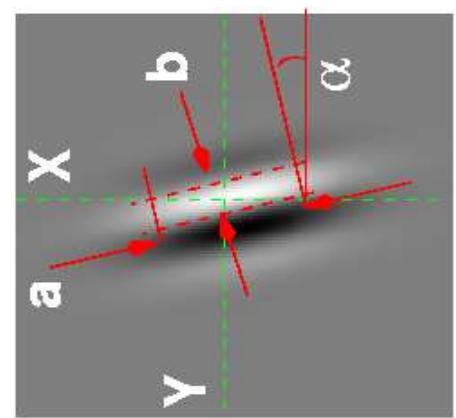
Rückblick Gabor Filter: Mathematische Beschreibung



$$\begin{bmatrix} x_g \\ y_g \end{bmatrix} = \begin{bmatrix} \cos(\alpha) & -\sin(\alpha) \\ \sin(\alpha) & \cos(\alpha) \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} \quad \arg_s = -2\pi \cdot \begin{bmatrix} u_0 \\ v_0 \end{bmatrix}^T \cdot \begin{bmatrix} x \\ y \end{bmatrix}^{-P}$$

$$\begin{bmatrix} u_0 \\ v_0 \end{bmatrix} = \begin{bmatrix} \cos(\phi_0) \\ \sin(\phi_0) \end{bmatrix} \cdot F_0 \quad \arg_E = -\frac{1}{2} \cdot \left(\frac{x_g^2}{a^2} + \frac{y_g^2}{b^2} \right)$$

Filter-Kernel: $G(x,y) = K \cdot \cos(\arg_s) \cdot e^{\arg_E}$ $G(x,y) = 0$	Parameter: $f_x \quad f_y \quad K \quad \phi_0 \quad \alpha \quad F_0 \quad P \quad a \quad b$
--	---



- Profilverlauf experimentell im V1 nachgewiesen

+ „Simple Cells“

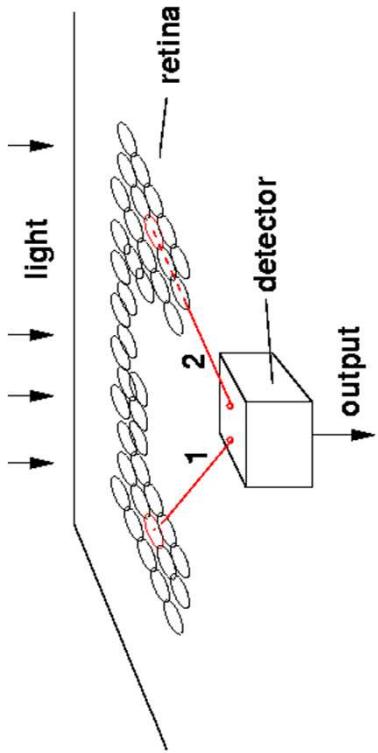
- Zweck: Detektion von lokalen Bildstrukturen
 - + charakterisiert durch spezifische Weite und Länge (a, b) sowie Orientierung (α)

Ausgangspunkt der Betrachtung: Detektion von Intensitätsgradienten

- 2-Punkt Detektion (2 Input, 1 Output)

• Spezifikation:

Detektor ist aktiv, wenn ein lokaler Intensitätsgradient mit bestimmter Richtung existiert



Experiment	expected output	Experiment	expected output
...	activity	...	no activity
...	activity	...	no activity
...	no activity	...	no activity
...	activity	...	no activity

○ : receptor



Baublock 1: der Minimum-Detektor

- Architekturkomponenten

- Analogs-Puls-Wandler
Neuron 1 & Neuron 2
- Korrelationsneuron
Neuron 3

- Gewichtsdynamik

$$\frac{dW_{KL}}{dt} = -\gamma \cdot W_{KL} + \mu \left(u_K - \frac{\theta}{2} \right) \cdot \chi(X_L)$$

$$W_{32} \geq 0 \quad W_{31} \geq 0$$

- Systemverhalten

- Membran-Potential (IAF-neuron):

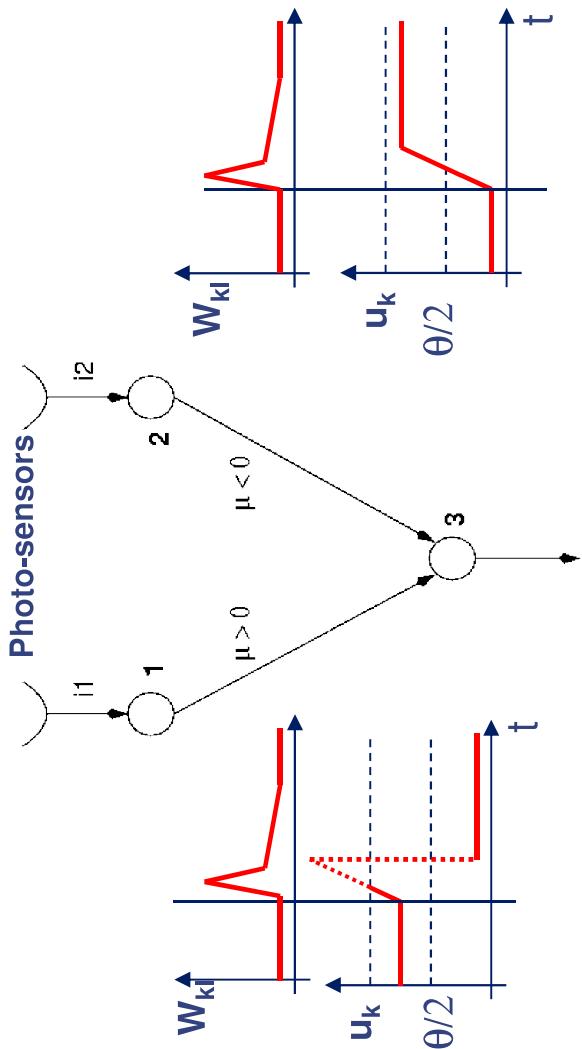
$$\frac{du_3}{dt} = \sum_L W_{3L} \cdot X_L$$

Ereignis	Anfangsbedingung		Endbedingung
	$u_3(0)$	$W_{KL}(0)$	
Neuron 2 feuert	0	0	$A \gg \theta/2$
Neuron 2 feuert	$A \gg \theta/2$	0	$A \gg \theta/2$
Neuron 1 feuert	$A \gg \theta/2$	0	$\geq \theta$
Neuron 1 feuert	0	0	0

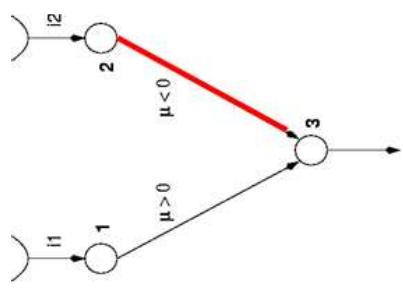
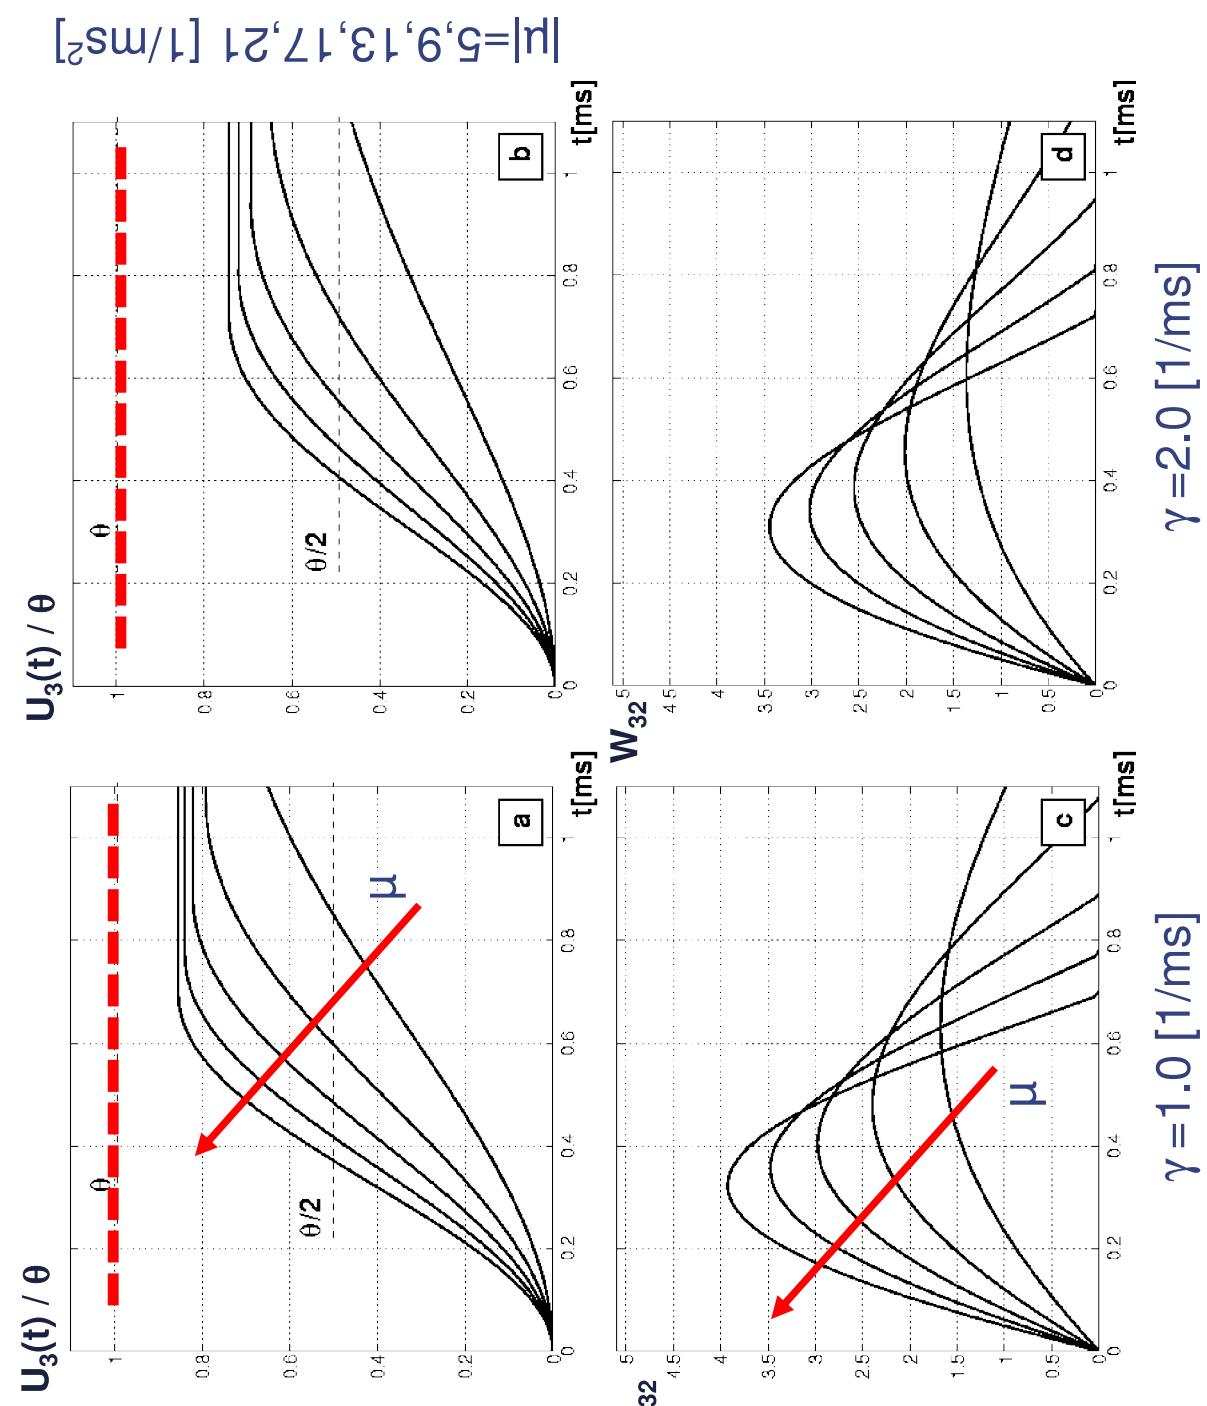
$u_3(t_d)$

Endbedingung

Aktion von Neuron 3



Verlauf von U_3 und W_{23} für $\mu < 0$, $U_3(0) = 0$



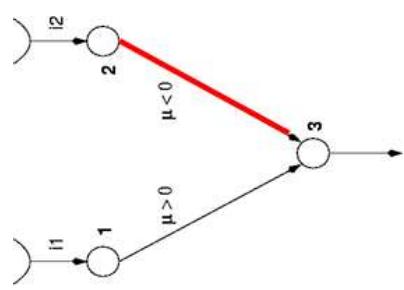
Fall I:

$$\mu < 0$$

$$X_2(t) = 1$$

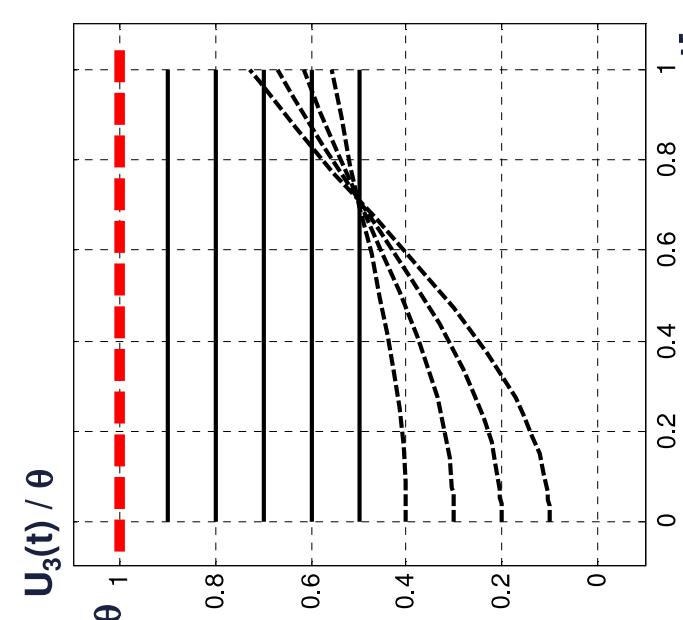
$$X_3(0) = 0$$

Verlauf von u_3 für $\mu < 0$, $u_3(0) > 0$



$$|\mu| = 5.0 \text{ [1/ms}^2]$$

$$U_3(t) / \theta$$



Fall I:

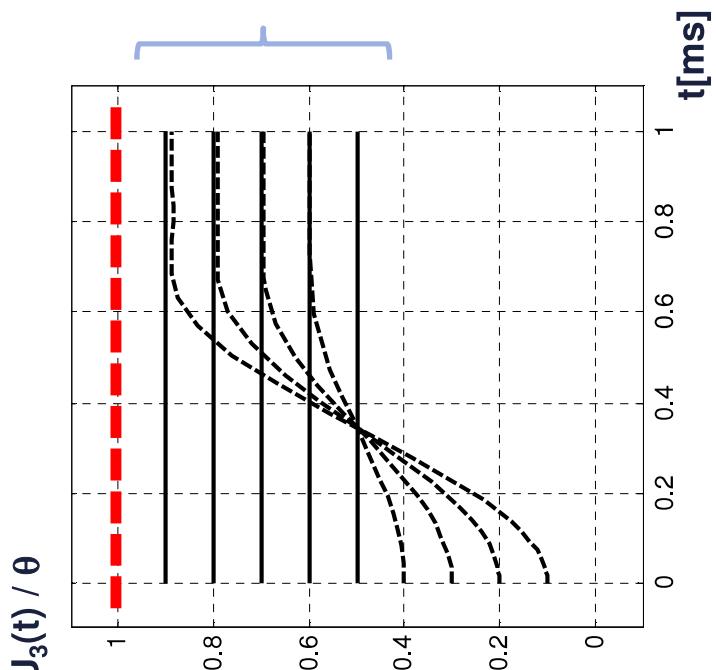
$$\mu < 0$$

$$X_2(t) = 1$$

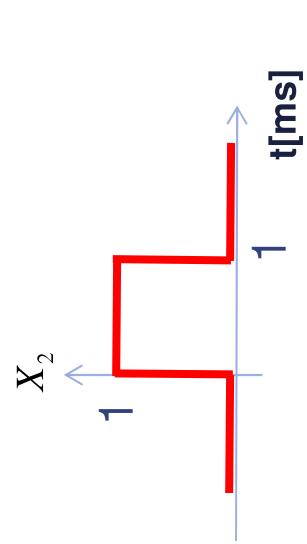
$$X_3(0) = 0$$

$$|\mu| = 21.0 \text{ [1/ms}^2]$$

$$U_3(t) / \theta$$



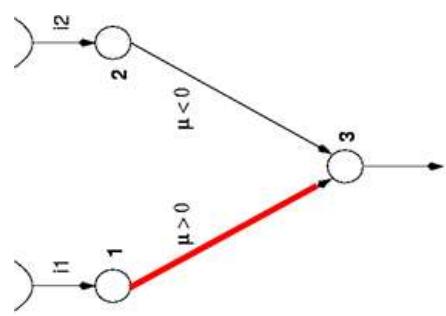
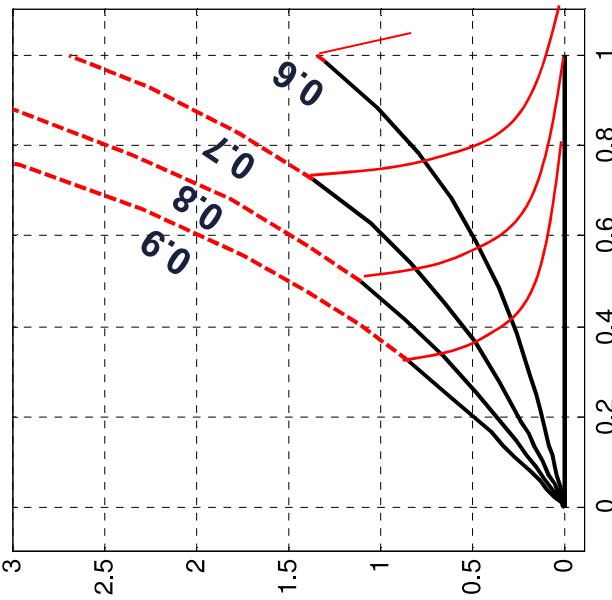
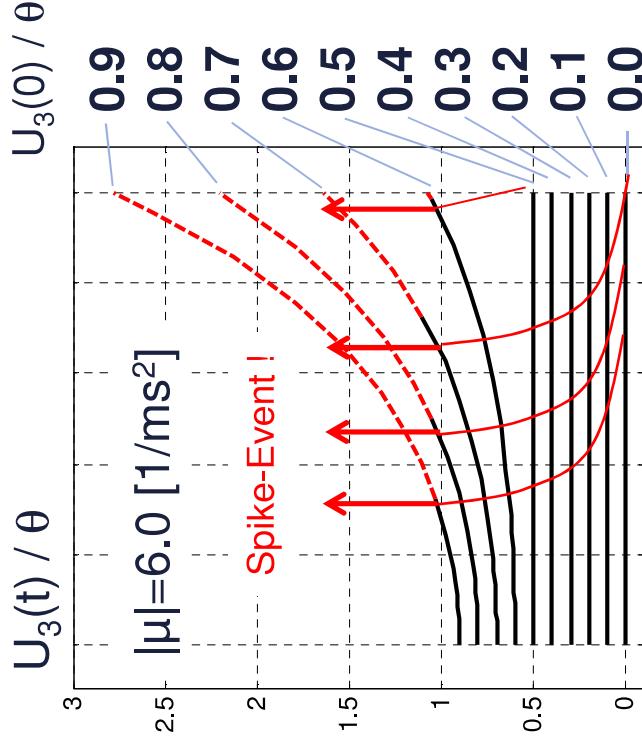
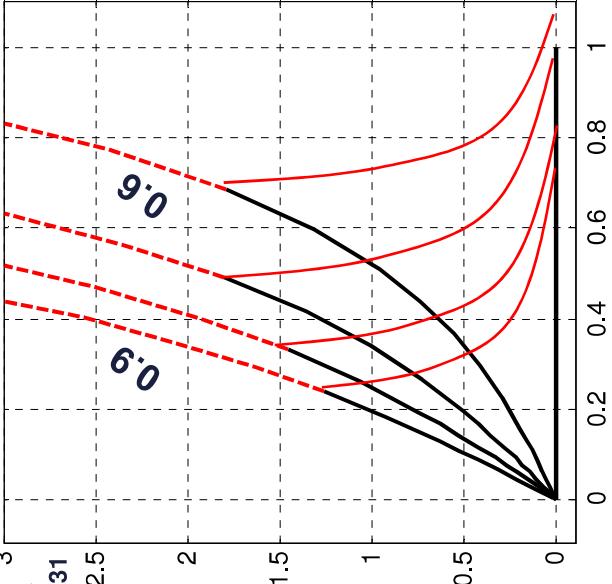
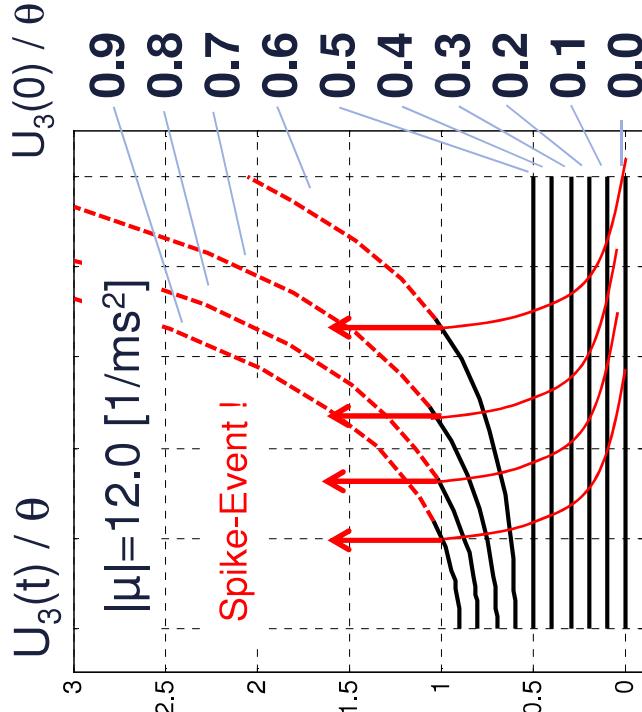
Kein Spike-Event!



$$\frac{dW_{32}}{dt} = -\gamma \cdot W_{32} + \mu \cdot \left(u_3 - \frac{\theta}{2} \right) \cdot \chi(X_2)$$

$$\frac{du_3}{dt} = W_{32} \cdot X_2$$





Fall III:

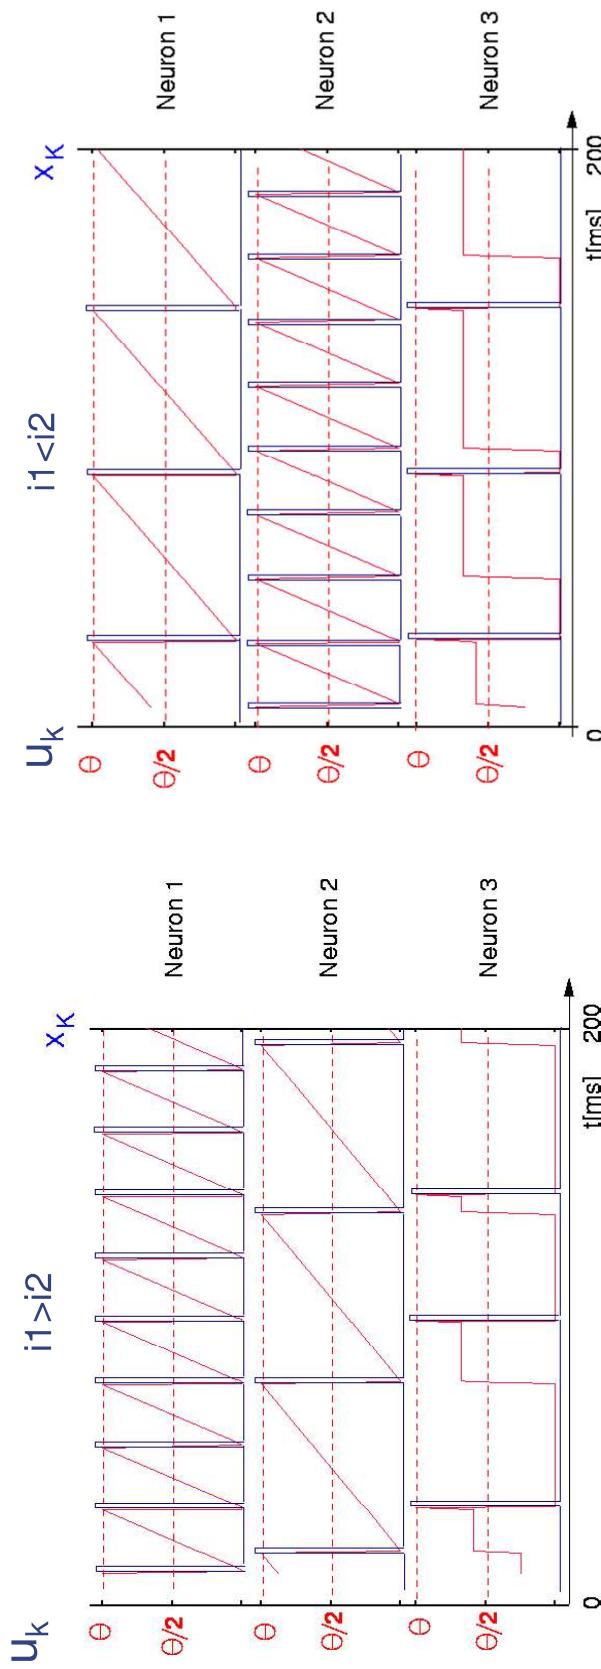
$$\mu > 0$$

$$X_1(t) = 1$$

$$X_3(0) = 0$$

Baublock 1: der Minimum-Detektor

- Beispiel: Systemdynamik für zwei verschiedene Eingangssignale



- Ziel: Analyse des Input-Output-Verhaltens für verschiedene Eingangssignale i_1, i_2

mögliche Ausgangsgrößen

- Pulsrate

- Korrelation:

- Dekorrelation

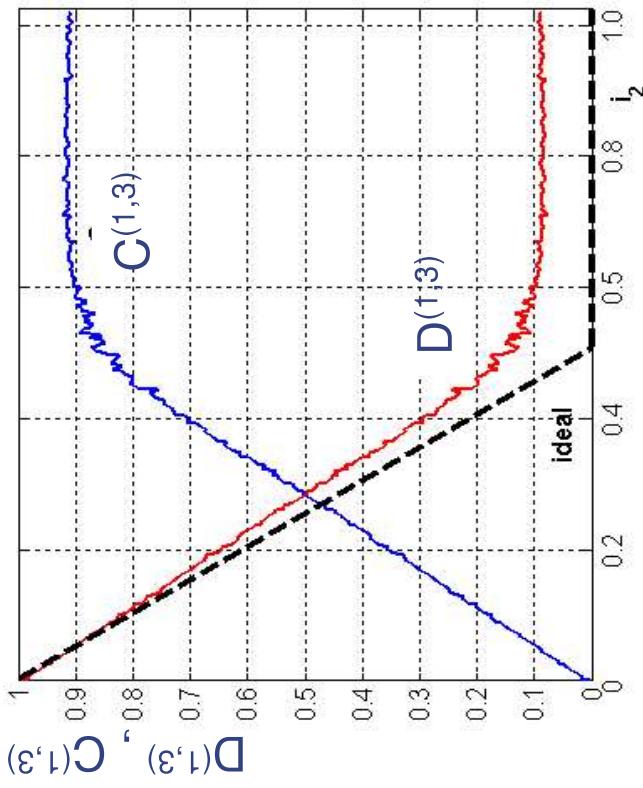
$$C^{(1,3)} = \frac{1}{T} \int_0^T X^{(1)}(\tau) \cdot X^{(3)}(\tau) d\tau$$

$$D^{(1,3)} = C^{(1,1)} - C^{(1,3)}$$

Ergebnisse

- Ziel: experimentelles Ausmessen der Input-Output-Relation
- experimentelle Randbedingungen: i_1 bleibt fix, i_2 variiert

- Darstellung der normierten Korrelationen:



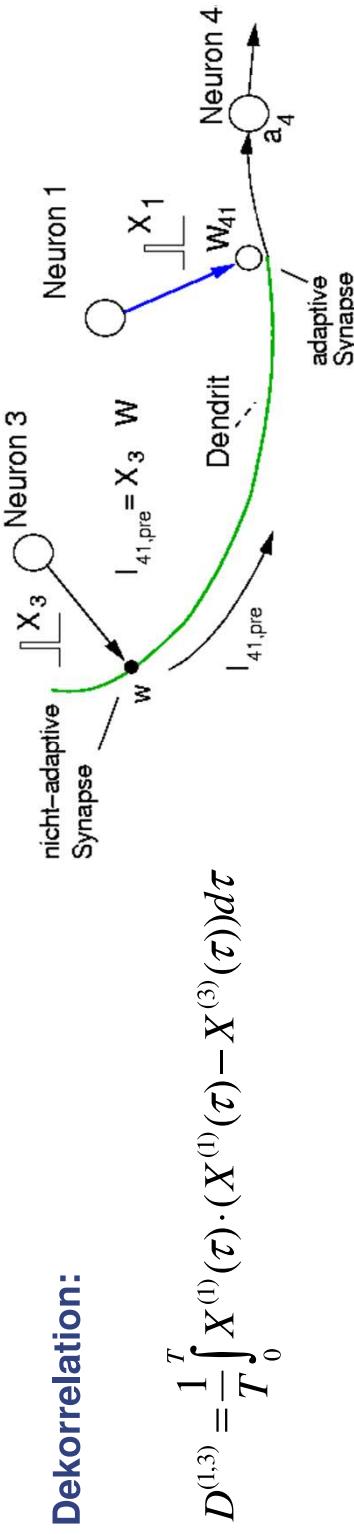
- $D^{(1,3)}$ fällt proportional zum Gradienten $(i_1 - i_2)$
- Ansatz: Gradienten können in dieser Architektur durch Messung von $D^{(1,3)}$ bestimmt werden.

Messung der Dekorrelation mit Hilfe dynamischer Synapsen

Einführung einer weiteren Schicht (Neuron 4)

+ Adaption der Synapse soll hier von *präsynaptischer* Aktivität abhängig sein

- keine präsynaptische Aktivität: -> Verstärkung der Synapse
- präsynaptische Aktivität vorhanden:
-> Abschwächen der Synapse

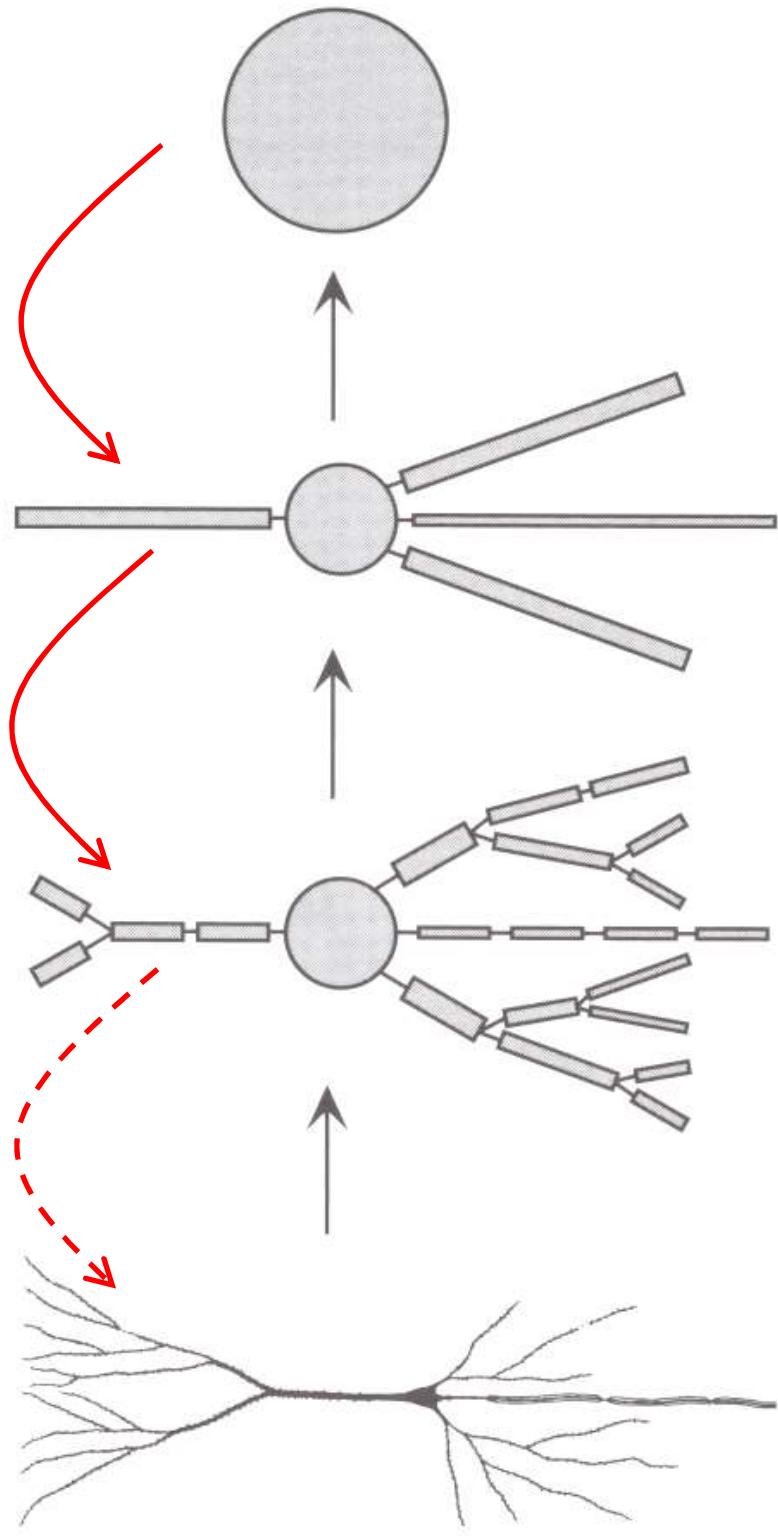


Dynamik der Synapse :

$$\frac{dW_{KL}}{dt} = -\gamma \cdot (W_{KL} - W_\infty) + \mu \cdot (I_{pre} - I_\theta) \cdot W_{KL} \cdot \chi(X_L) \quad \mu < 0 \quad I_\theta > 0$$



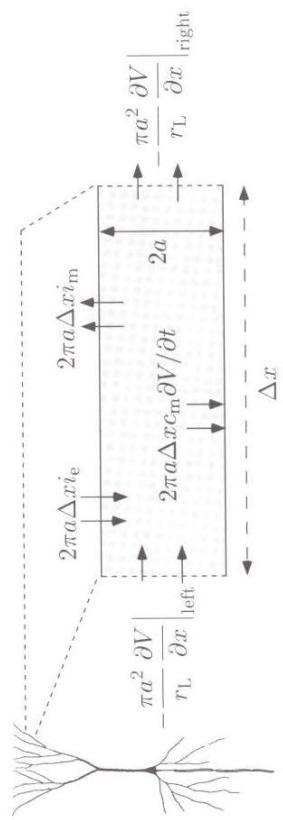
■ Compartment Model of a Neuron, Dendrite & Axon



single-compartment

multi-compartment

Pyramidal Cell



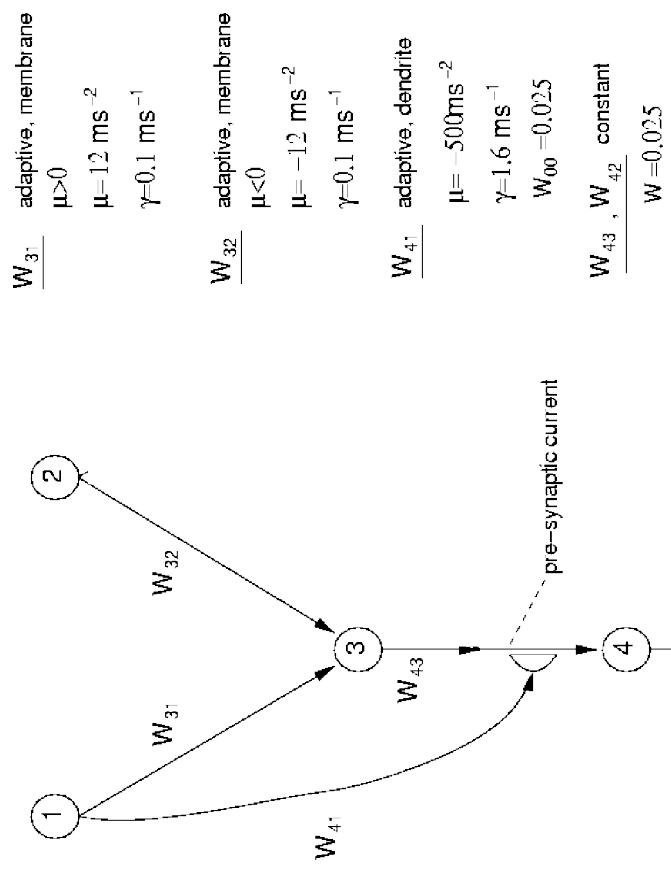
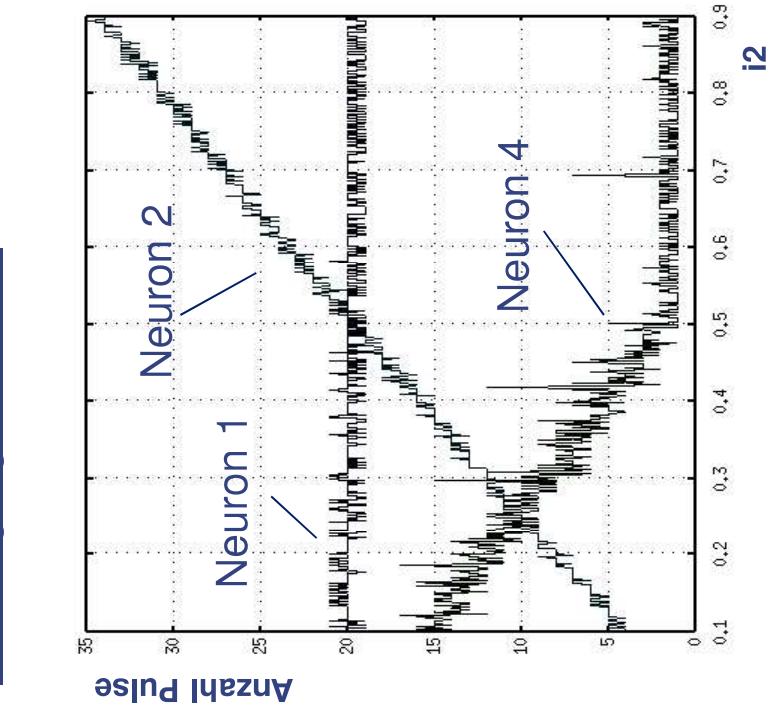
Einfluß der räumlichen Anordnung ?

From: P. Dayan, L.F. Abbott, "Theoretical Neuroscience", MIT Press



Der Gradientendetektor

Übertragungsverhalten:



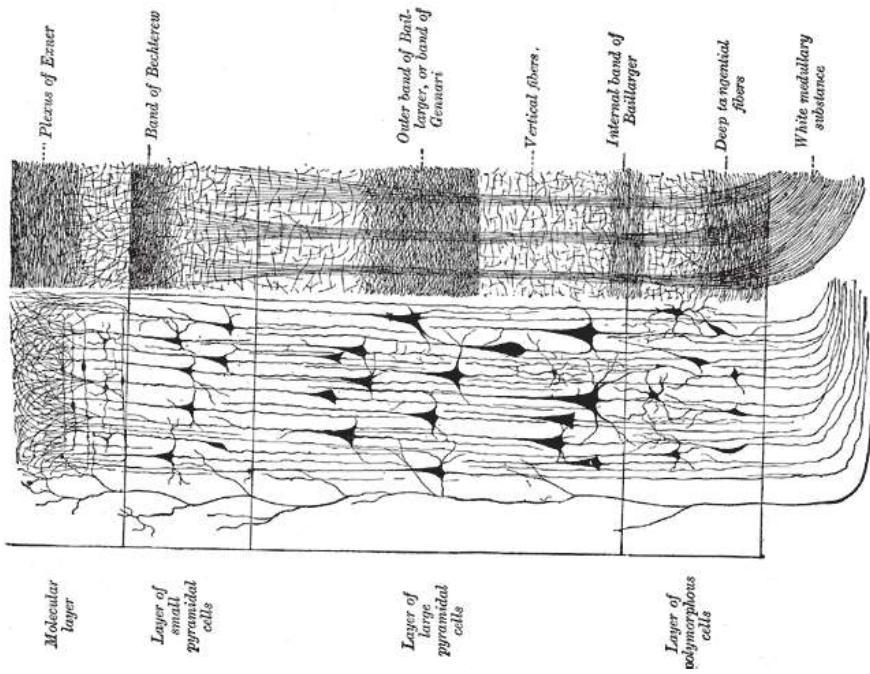
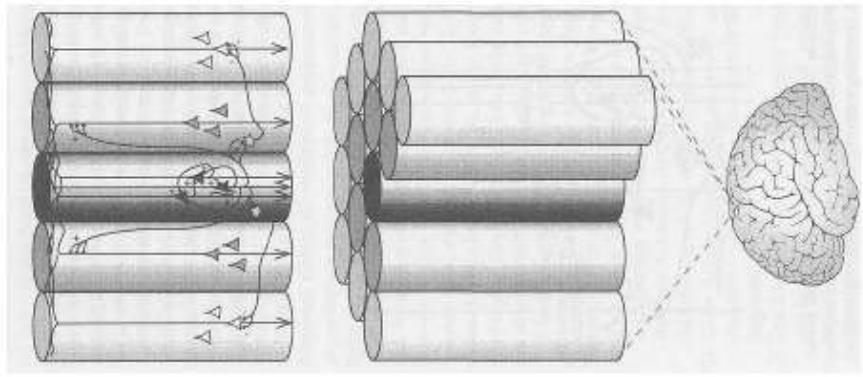
- ausschließlich positive Synapsengewichte
- dynamische und konstante Synapsen
 - + Membranregel
 - + Dendritenregel
 - + konstante Synapsen (präsynaptischer Strom)

$$\begin{aligned} i_1 &= 0.5 \\ \Theta &= 1 \\ W_{k0} &= 0.08 \\ t_d &= 1 \text{ ms} \\ T &= 500 \text{ ms} \end{aligned}$$

■ Hierarchy

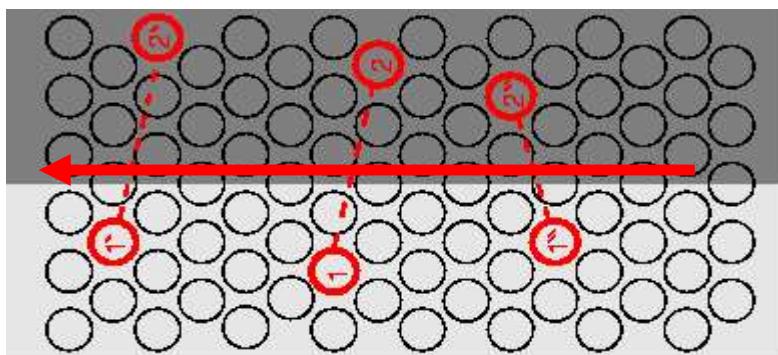
- (I) Layers
- (II) Cortical Minicolumns (Microcolumn)
~ 80-140 Neurons
- (III) Cortical Hypercolumns
(Macrocolumn, Module)

(IV) Overlap of Hypercolumns



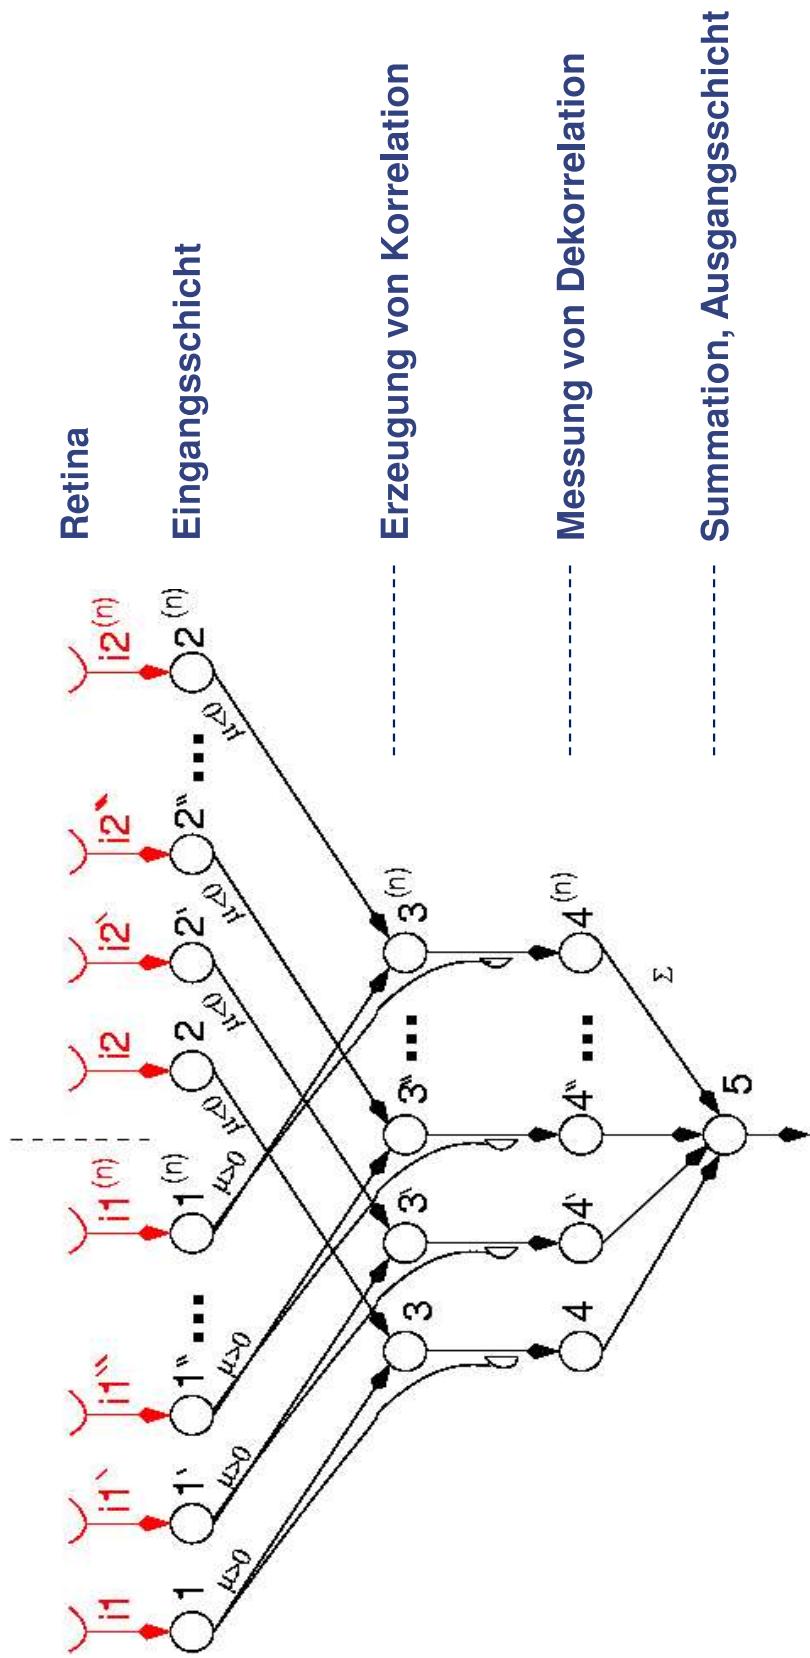
Detektion räumlich ausgedehnter Strukturen: Kanten, Linien

- Betrachtung eines Auschnitts aus der Retina
- Intensitätsverteilung einer zu detektierenden Kante
- Detektion eines Grauwert-Gradienten zwischen Pixel 1 und Pixel 2 ergibt Information über einen *lokalen* Gradienten
- Verteilte Detektion von lokalen Gradienten längs einer vorgegebenen Richtung. Je mehr Detektoren Gradienten detektieren, desto höher die Wahrscheinlichkeit, daß eine Kante längs der vorgegebenen Richtung vorliegt
- Verknüpfung der Ausgänge der einzelnen Detektoren durch Summation der Ausgangspulse



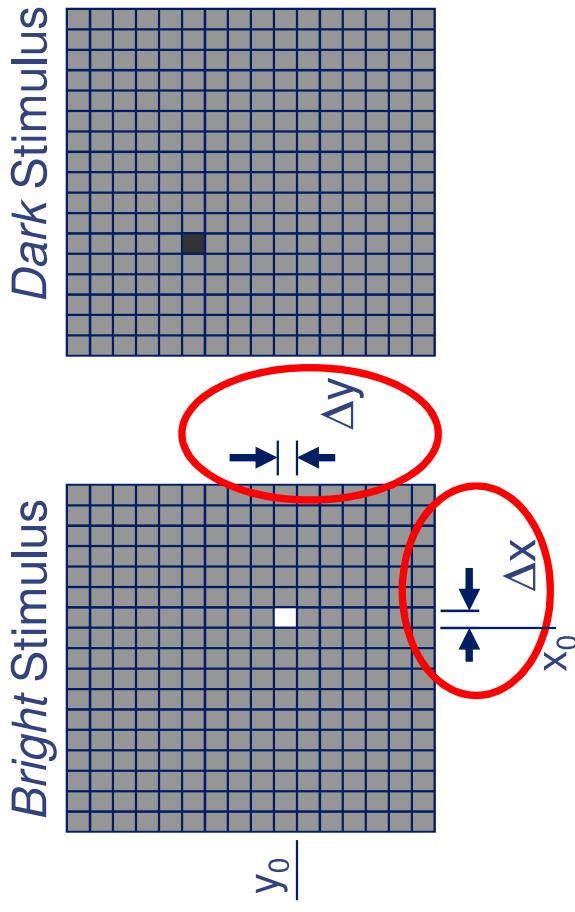
○ : **Receptor**

Architektur eines Liniedetektors



- Komplexe Detektoren entstehen durch Vernetzung einzelner Gradientendetektoren
- weiterführende Fragestellung: Wie entstehen Detektorprofile?

Review: experimentelle Abtastung des RF

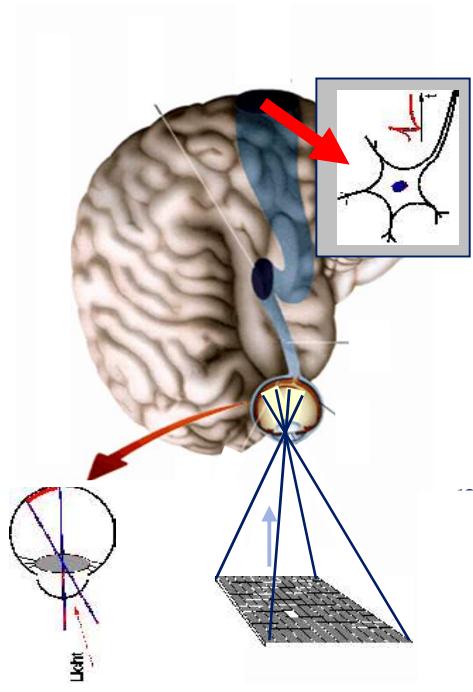


Stimuli, projiziert auf RF einer Simple Cell

experimentelle Anordnung

$$\Pi(x_0, y_0) \approx (H - B) \cdot \iint_{(x_0, x_0 + \Delta x) \times (y_0, y_0 + \Delta y)} G_i(x, y) dx dy$$

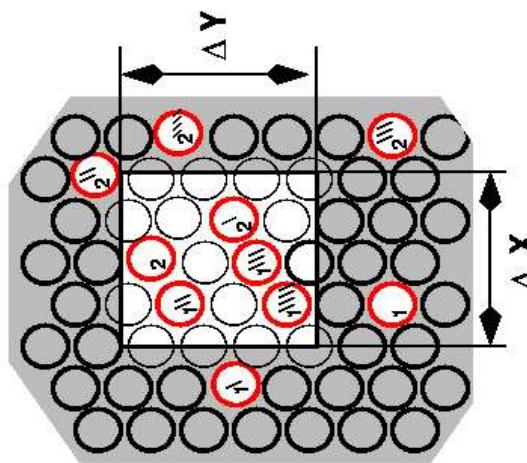
Π : gemessene average spike rate G_i : Gaborfunktion H : Spot Intensität B : Background Intensität



Formgebung eines beliebigen Detektorprofils

- Allgemeine Annahme: die Rezeptoren, die mit der Eingangsschicht eines Detektors i verbunden sind, liegen räumlich verteilt auf der Retina
 - Die räumliche Verteilung werde beschrieben über zwei Dichtefunktionen $\rho^1(x,y)$ und $\rho^2(x,y)$ (Verbindungsichte zu 1- bzw. 2-Neuronen)

- Bei Aktivierung der Retina mit einem Spot (Dark, Bright) werden \mathbf{N}^1 1-Neuronen und \mathbf{N}^2 2-Neuronen aktiviert:



$$N_i^1(x_0, y_0) = \iint_{(x_0, y_0) + \Delta x \times (y_0, y_0 + \Delta y)} \rho_i^1(x, y) dx dy$$

$$N_i^2(x_0, y_0) = \iint_{(x_0, y_0) + \Delta x \times (y_0, y_0 + \Delta y)} \rho_i^2(x, y) dx dy$$

- Ausgangspulsrate des Detektors:

$$\Pi(x_0, y_0) = \frac{W_{K0}}{\Theta} \cdot (H - B) \cdot (N_i^1(x_0, y_0) - N_i^2(x_0, y_0))$$

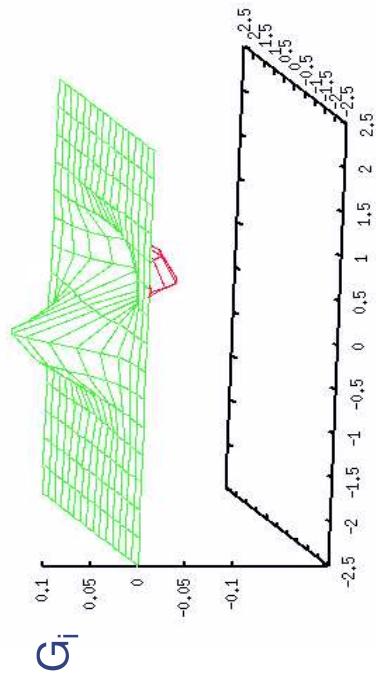
Ausschnitt der Retina

- Das Profil $\mathbf{G}_i(x,y)$ des Detektors folgt damit:

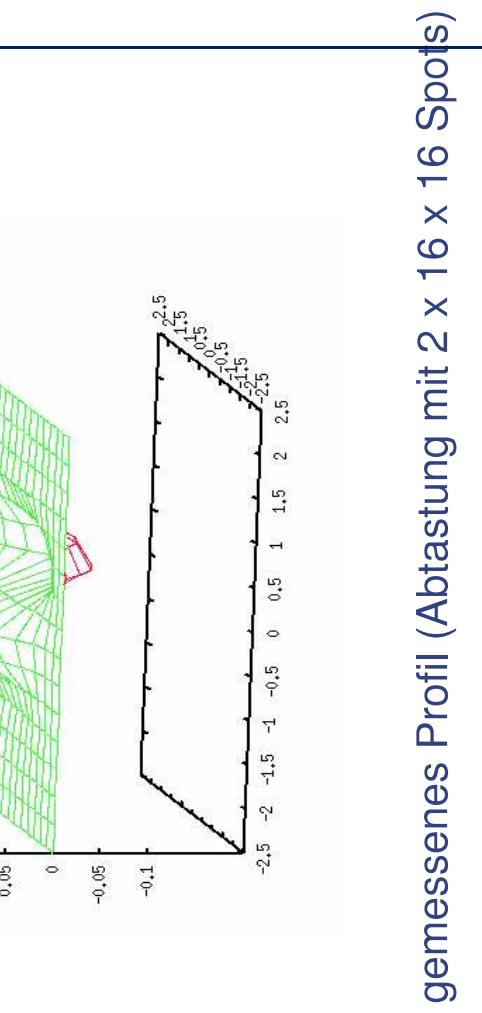
$$\Rightarrow \rho_i^1(x, y) - \rho_i^2(x, y) = \frac{\Theta}{W_{K0}} G_i(x, y)$$

Beispiel einer Detektorimplementierung

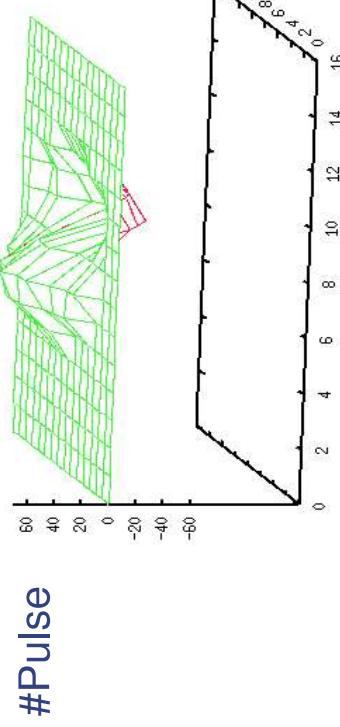
Ideales Profil $G_i(x,y)$



- Verbindung der Rezeptorschicht mit Eingangsschicht des Detektors (128 Neuronen)



gemessenes Profil (Abtastung mit $2 \times 16 \times 16$ Spots)

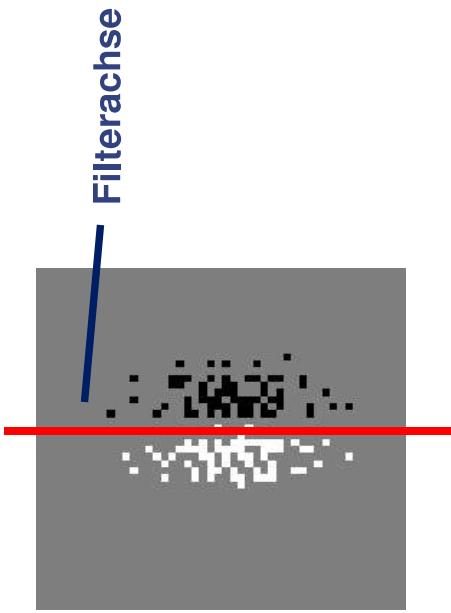


- Rezeptor ist mit einem 1-Neuron verbunden
- Rezeptor ist mit einem 2-Neuron verbunden
- Rezeptor ist nicht verbunden

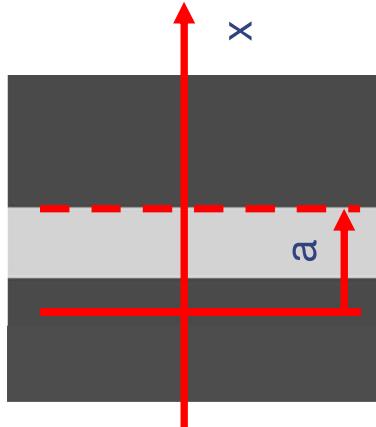
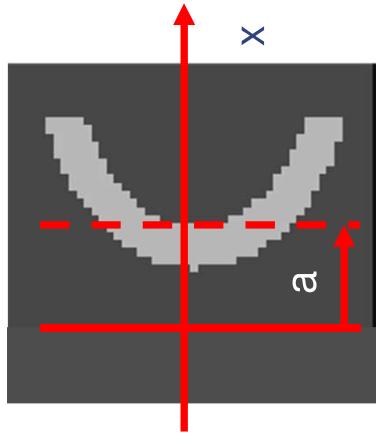
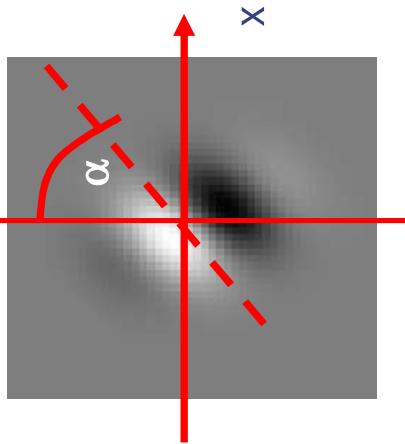
Weitere Experimente zur Vermessung des Detektors

3 Experimente zur Filtercharakterisierung

- Nachweis der Sensitivität für räumliche Strukturen
 - + Verschiebung & Rotation
 - Vergleich mit idealem Gabor-Filter



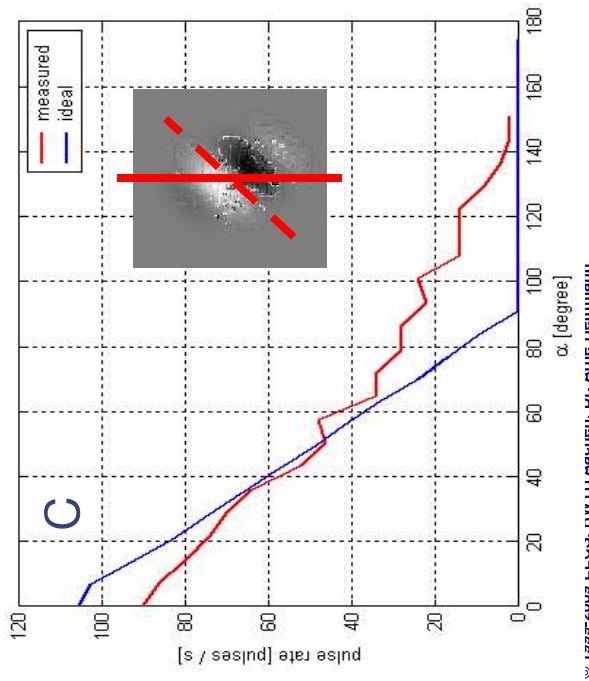
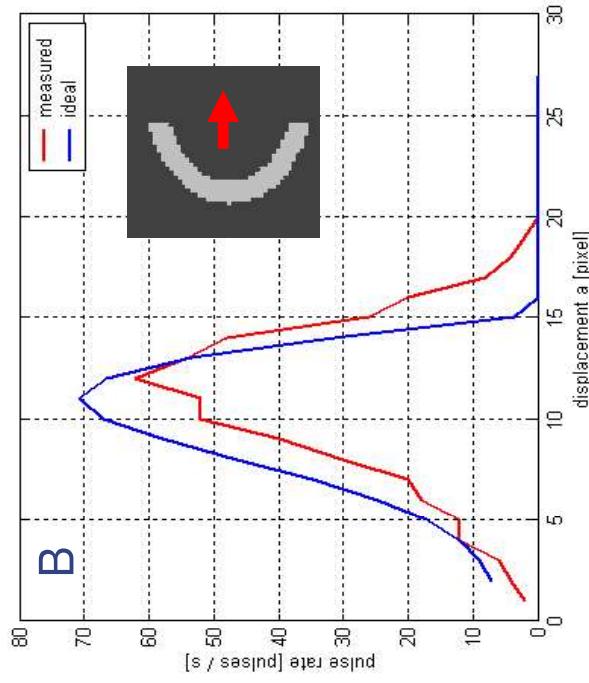
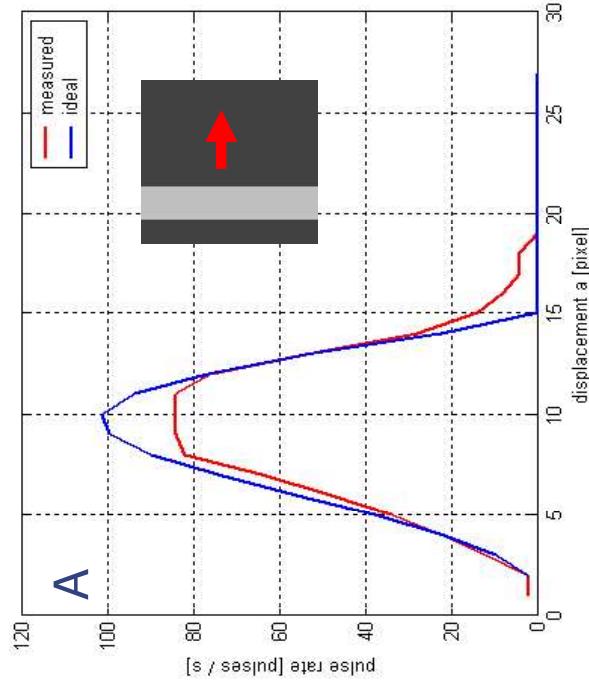
- Verschiebung einer Linie in x-Richtung, **Symmetrie** der Bildstruktur bezüglich der Filterachse
 - Detektion von Kanten
- Verschiebung einer Kurve in x-Richtung, **Unsymmetrie** der Bildstruktur bezüglich der Filterachse
 - geringere Ausgangsaktivität als im linken Fall
- Rotation einer Bildstruktur
 - Nachweis der **Sensitivität des Detektors für Orientierungen**



Experimente

- 128 Neurone in der Eingangsschicht $W_{K0} = 0.05$
- $T = 500\text{ns}$

$H = 0.75$ (Linie)
 $B = 0.25$ (Hintergrund)



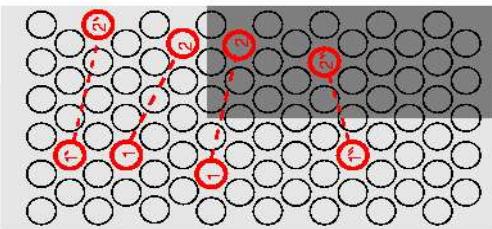
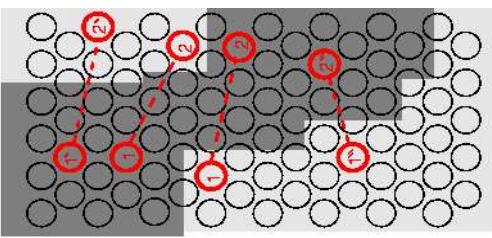
Resultat:

- gute Übereinstimmung der theoretischen Kurve mit praktischen Ergebnissen in A, B
- schlechte Übereinstimmung der theoretischen Kurve mit praktischen Ergebnissen in C, gemessener Detektor hat geringere Selektivität

Verbesserung der Selektivität des Detektors

Beispiel: gezeigt sind vier Gradientendetektoren, die zu einem Detektor gehören (sensitiv für vertikale Kanten).

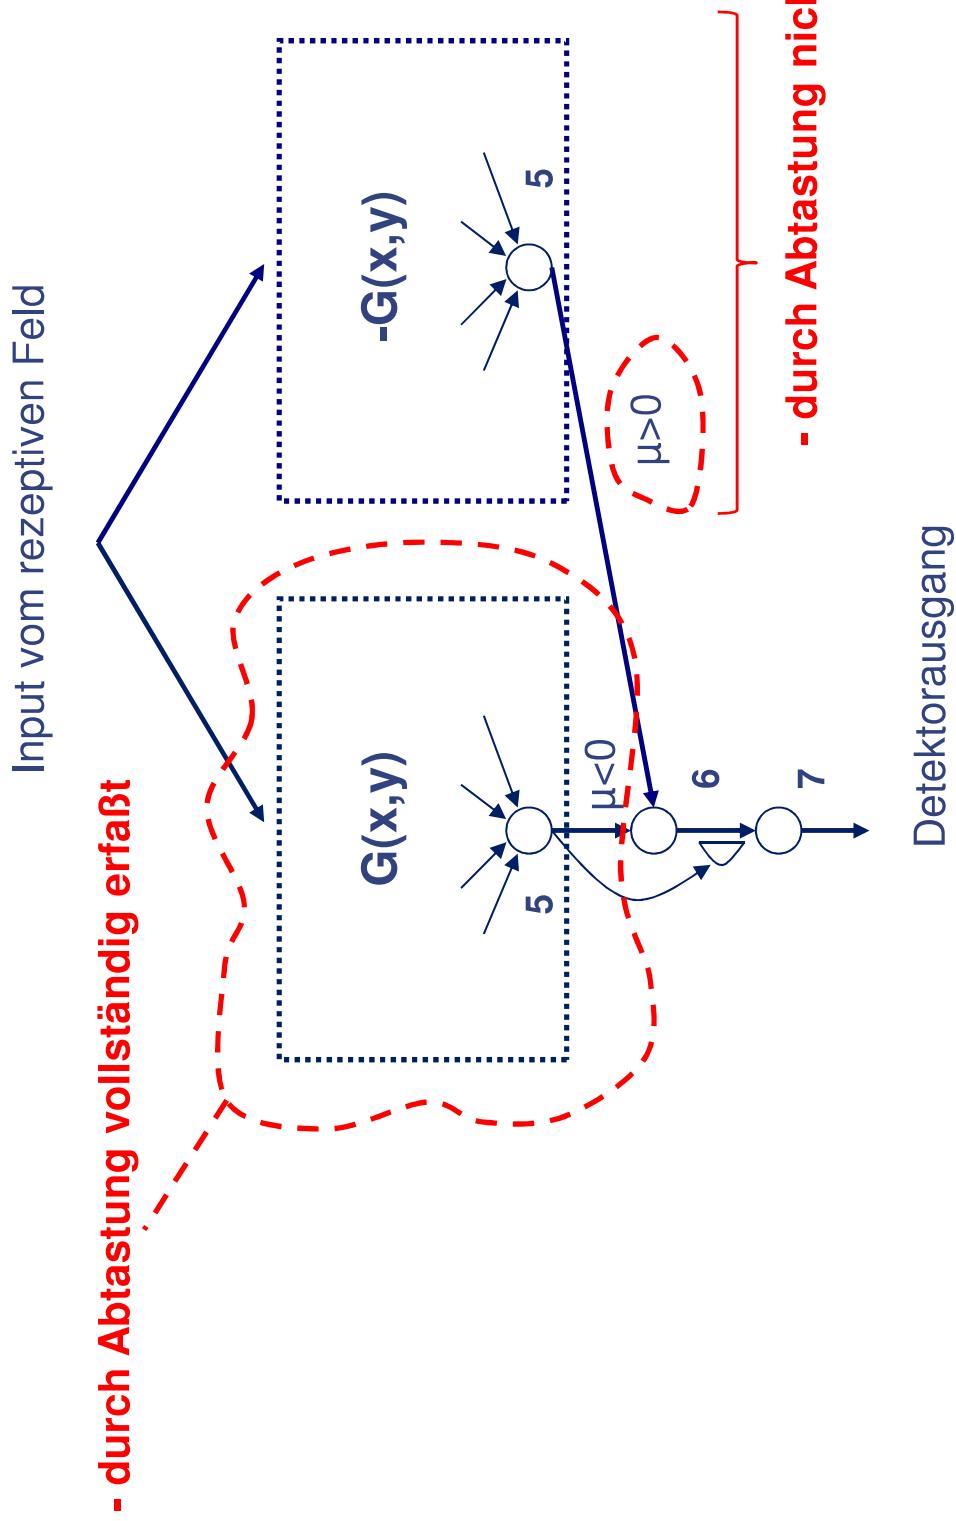
- unter den gegebenen Intensitätsverteilungen sind die Filterantworten in beiden Fällen identisch, die Struktur rechts (schräge Kante) paßt jedoch „schlechter“ zum Detektorprofil als die linke (Ende einer vertikalen Kante)



○ : Receptor

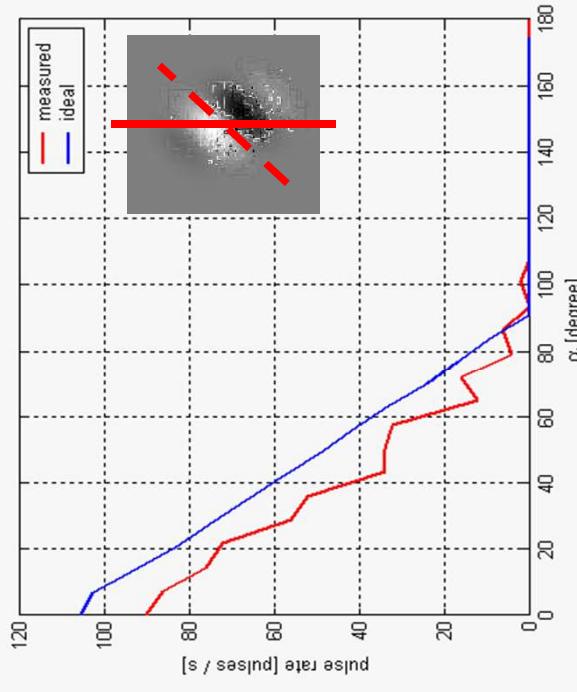
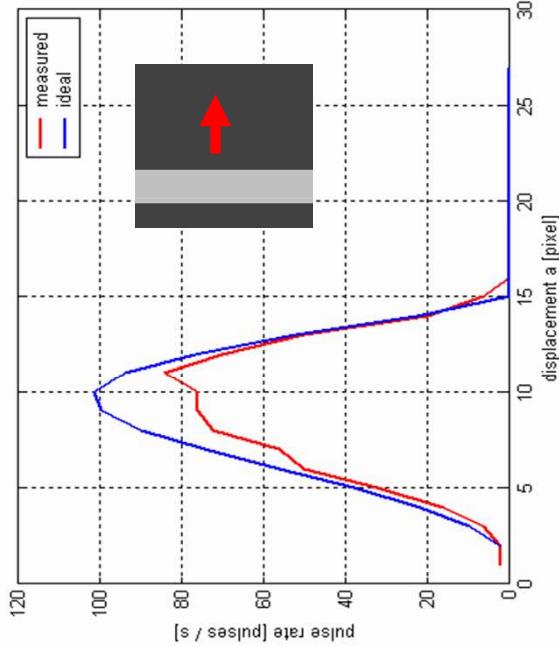
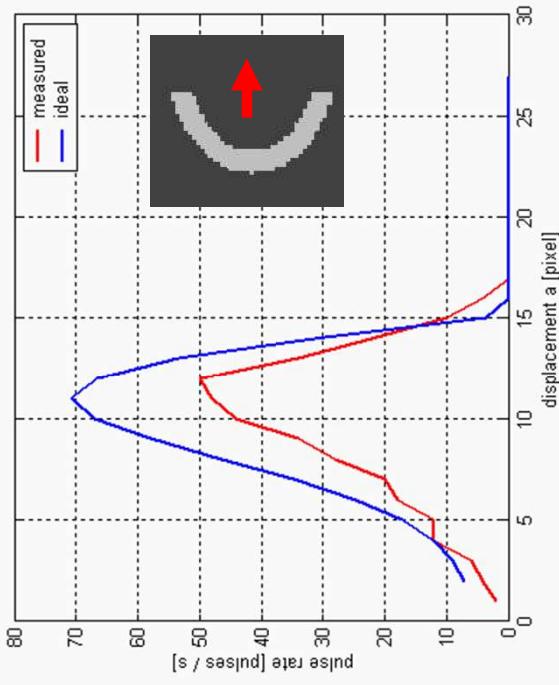
Lösungsansatz: + Implementierung eines zweiten Detektors mit identischem rezeptiven Feld, jedoch negiertem Detektorprofil $-G_i(x,y)$
+ Kombination der beiden Filter durch Subtraktion der Ausgangspulse

Verbesserte Detektorarchitektur



- Einsatz eines Gradientendetektors zur Realisierung der Subtraktion von Pulsen

Experimente mit verbesselter Architektur

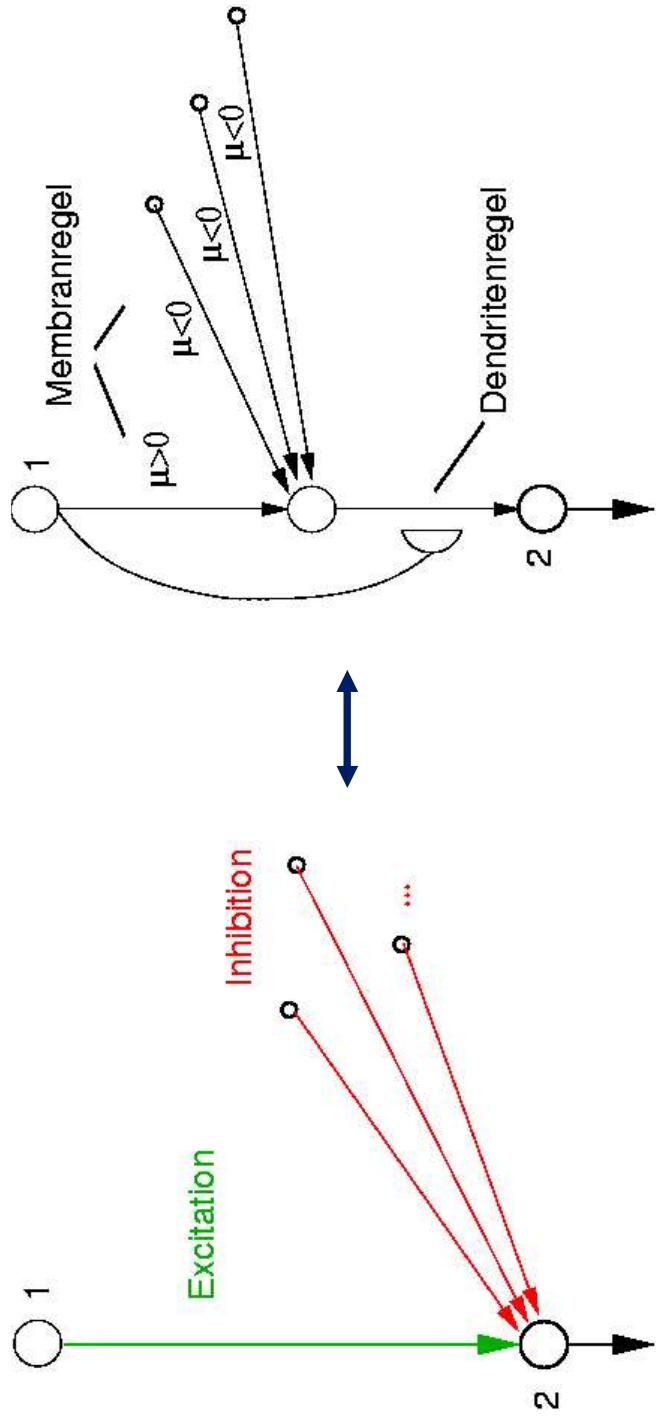


- Resultat

Detektoren erreichen die Linearität
der idealen Gabor-Filter

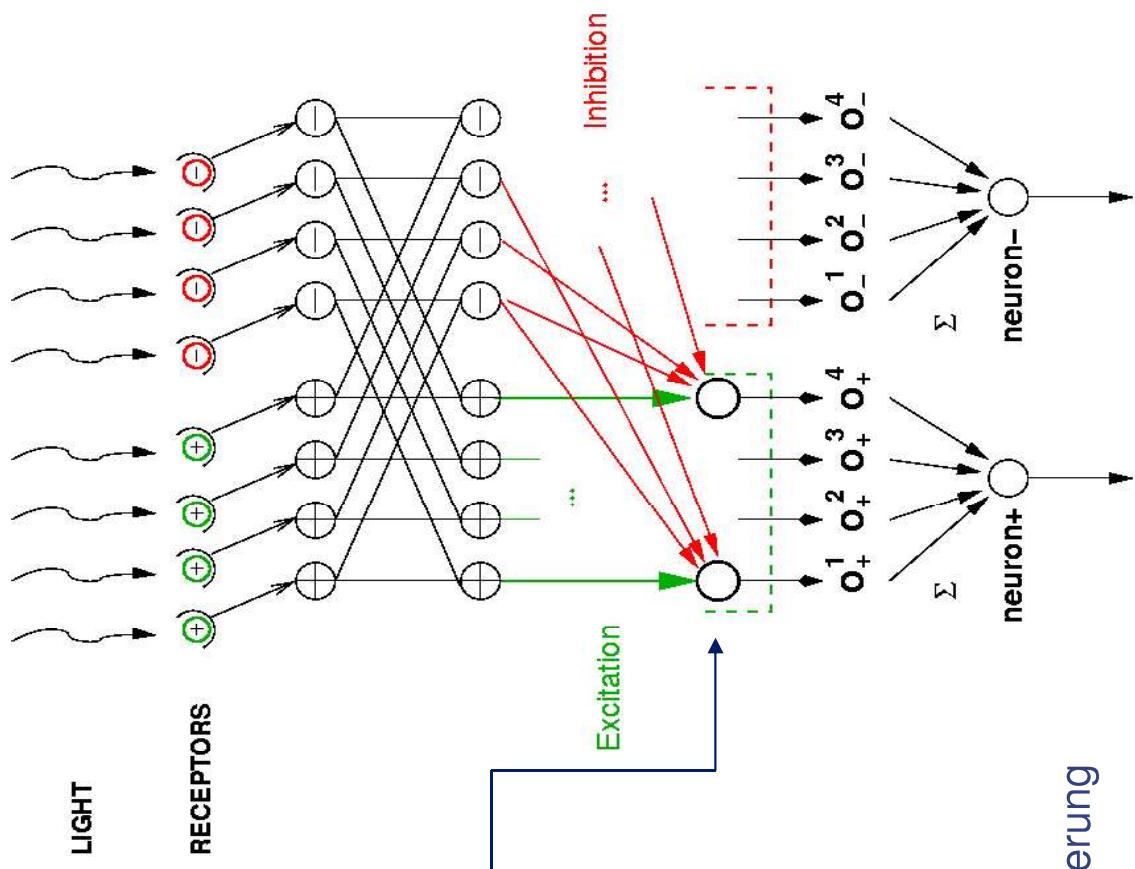
Weitere Massnahmen zur Verbesserung der Selektivität

- Erweiterung des Minimum-Detektors



- Analogie zwischen Excitation/Inhibition und dynamischen Synapsen

Einführung lateraler Inhibition



- + Forderung: wirksame Unterdrückung der Ausgangsaktivität
- Inhibition hemmt jedes Zwischenneuron

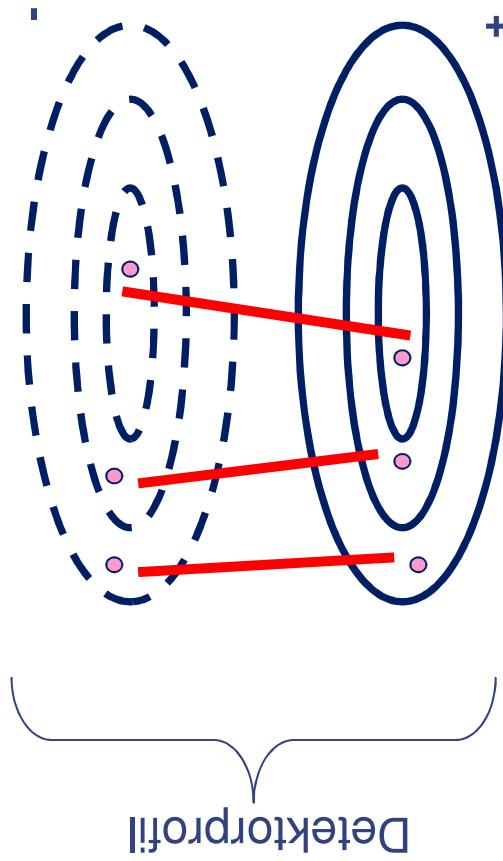
+ Inhibition kann stärker oder schwächer ausgelegt sein als im linearen Fall, diese ist abhängig von der Anzahl der inhibitorischen Verbindungen

- Auswirkungen der Inhibition auf die Selektivität des Detektors
 - + mehr inhibitorische Verbindungen bedingt höhere Selektivität
 - + schärfere Abgrenzung senkrecht zur Orientierung

Zuordnungsstrategien von Inhibition und Excitation

- Randbedingung: Abtasteigenschaft des rezeptiven Feldes soll erhalten bleiben

Differenzbildung (paarweise)

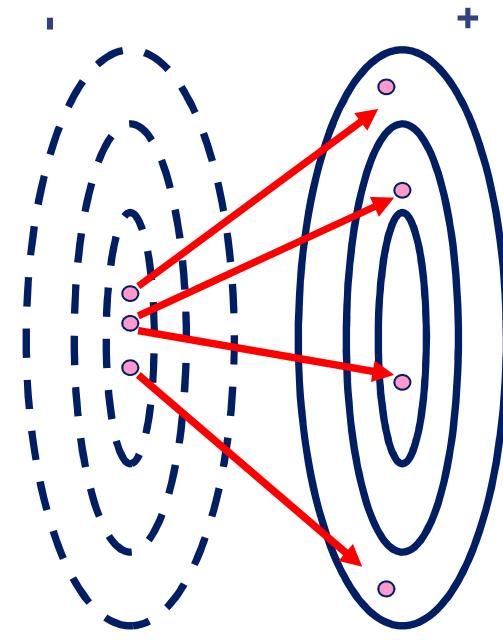


Aufsicht eines Detektorprofils

mögliche Strategie:

- + Differenzbildung jeweils zwischen Rezeptoren aus Bereichen ähnlicher Dichte

„Inhibition“



Aufsicht eines Detektorprofils

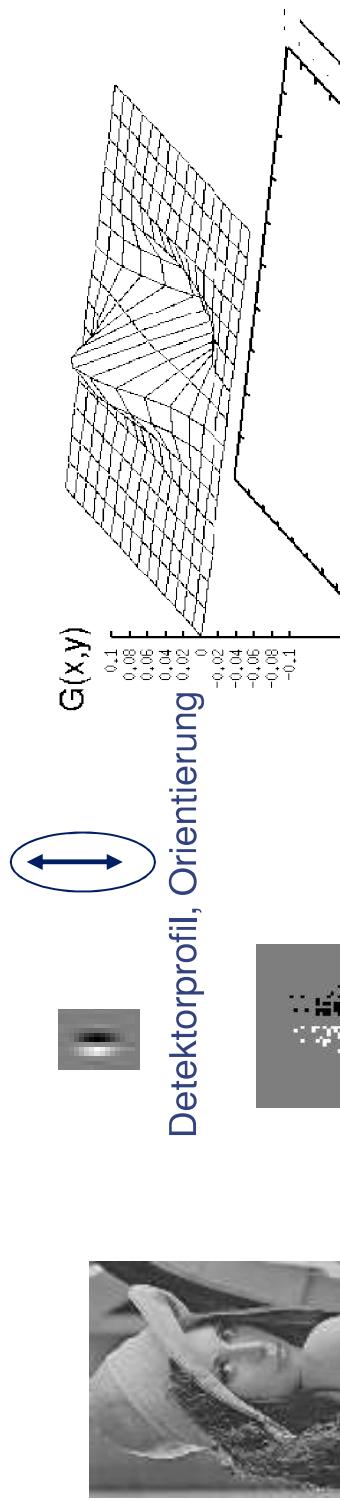
mögliche Strategie:

- + aus den Bereichen hoher Dichte

Experiment

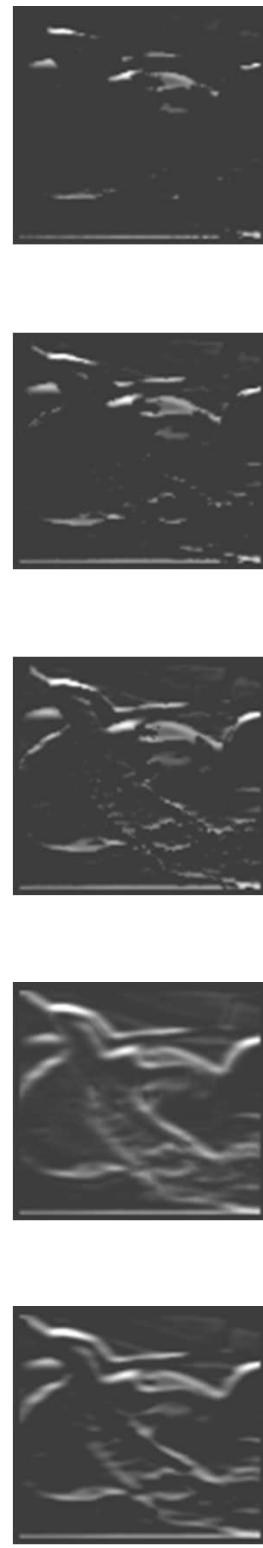
Szene, 96 x 96 Pixel

Filterprofil, 16 x 16 Pixel, 128 Rezeptoren (64+, 64-)



Rezeptorprofil, 16 x 16 Pixel, 3 x 3 Rezeptoren pro Pixel

Gabor, linear
Gabor, nicht-lineär

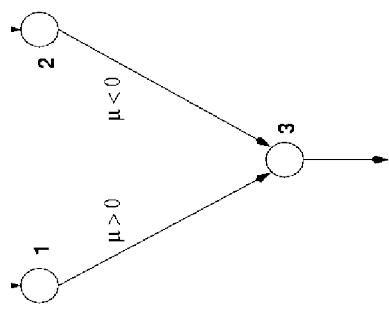


Inhibition = 0 Verbind. Inhibition = 20 Verbind. Inhibition = 40 Verbind. Inhibition = 60 Verbind.

Minimumdetektor mit statistisch verteilten Eingangspulsen

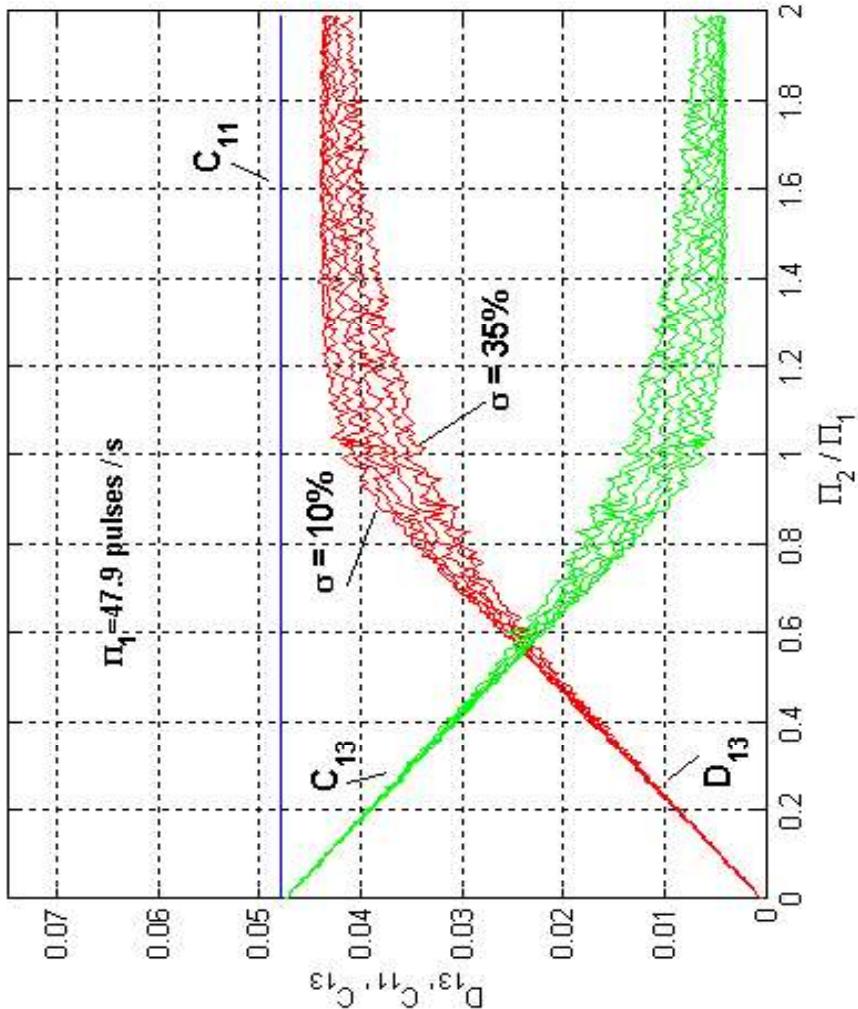
Pulsabstände von Neuron 1 und Neuron 2 werden statistisch variiert

+ Modellierung der Variation mit einer Gauß-Verteilung (σ, μ)



$$\Pi_1 = 47,9 \text{ pulses/s}$$

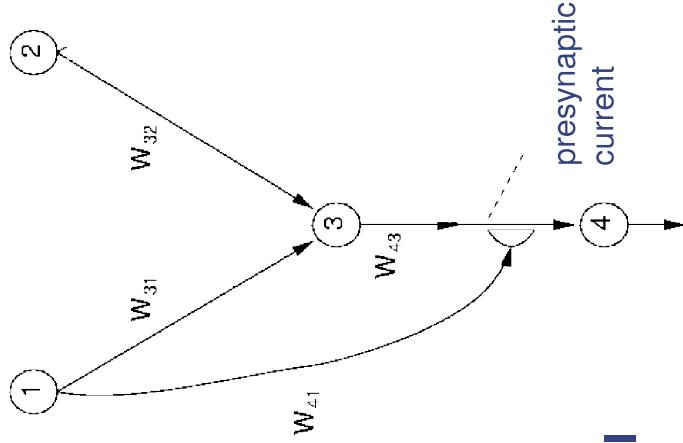
$$\begin{aligned} \Theta &= 1 \\ W_{K0} &= 0.1 \\ t_d &= 1 \text{ ms} \\ |\mu| &= 12 \text{ ms}^{-2} \\ \gamma &= 0.1 \text{ ms} \\ T &= 20 \text{ s} \end{aligned}$$



Gradientendetektor mit statistisch verteilten Eingangspulsen

Pulsabstände von Neuron 1 und Neuron 2 werden statistisch variiert

+ Modellierung der Variation mit einer Gauß-Verteilung (σ, μ)



$$\Pi_1 = 47,9 \text{ pul}$$

$$\begin{aligned} \Theta &= 1 \\ W_{K0} &= 0.1 \\ t_d &= 1 \text{ ms} \\ |\mu| &= 12 \text{ ms}^{-2} \\ \gamma &= 0.1 \text{ ms} \\ T &= 20 \text{ s} \end{aligned}$$

